ОТЧЁТ ПО СЕМИНАРУ И ДОМАШНЕЙ РАБОТЕ

ChIP-seq Foxd3 на четырёх стадиях развития нервного гребня Danio rerio

Danio rerio, сборка GRCz11

2026

1. Цель, логика анализа и главный результат

Цель. По одному и тому же учебному workflow построить и интерпретировать карты связывания транскрипционного фактора Foxd3 для четырёх стадий развития: 75 % эпиболии (75ep), 1–2 сомита (1–2ss), 5–6 сомитов (5–6ss) и 14 сомитов (14ss). Для 14ss workflow выполнен на семинаре, для 75ep и 1–2ss — самостоятельно, а набор 5–6ss предоставлен преподавателем.

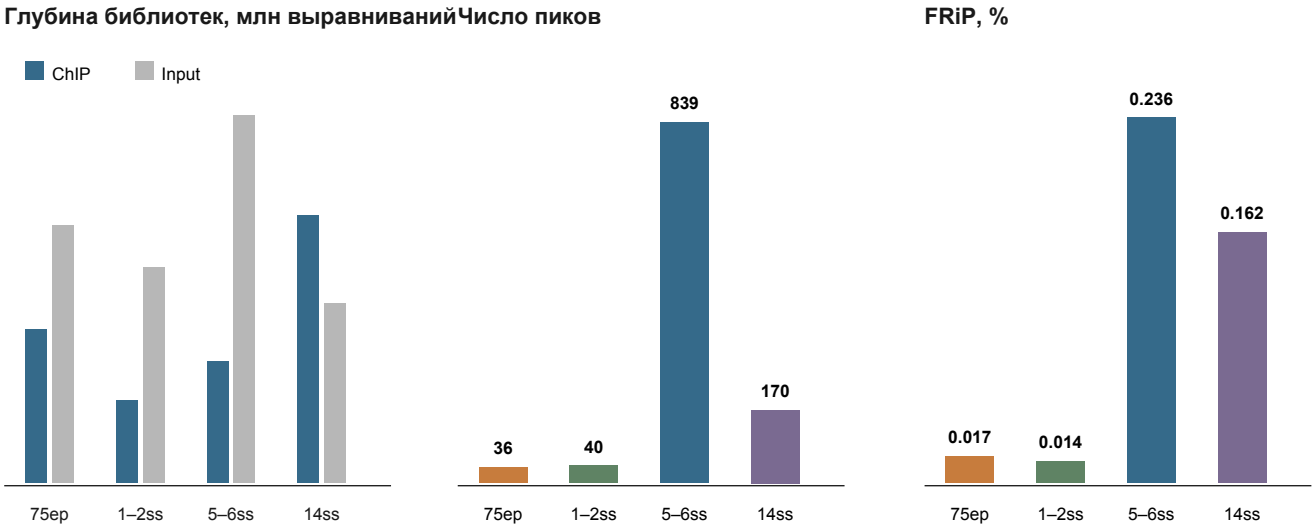


Рис. 1. Сводка по четырём стадиям. Высота столбцов показывает глубину библиотек, число вызванных пиков и read-based FRiP. Точные значения подписаны; разные панели имеют разные шкалы.

2. Биологический и экспериментальный контекст

2.1. Foxd3 и нервный гребень

Foxd3 — транскрипционный фактор семейства forkhead, важный для формирования нервного гребня. В работе Lukoseviciute et al. показано, что его функция меняется во времени: на ранних этапах Foxd3 способствует подготовке и открытию регуляторных элементов, а позже участвует в репрессии части программ дифференцировки. Такое утверждение основано на совместной интерпретации Foxd3 bioChIP-seq, ATAC-seq, H3K27ac ChIP-seq и RNA-seq. Один ChIP-seq показывает место связывания, но сам по себе не различает активацию и репрессию.

Стадия	Примерное время	Биологический этап	Источник результата
75ep	≈8 hpf	поздняя гаструляция; ранние предшественники	самостоятельный анализ
1–2ss	≈10,3–10,7 hpf	индукция нервного гребня	самостоятельный анализ
5–6ss	≈11,7–12 hpf	спецификация нервного гребня	файлы преподавателя
14ss	≈16 hpf	начало/стадия миграции нервного гребня	семинарский анализ

Табл. 1. Стадии расположены в хронологическом порядке. hpf — часы после оплодотворения.

2.2. Что измеряет ChIP-seq

После фиксации белок–ДНК хроматин фрагментируют. Фрагменты, связанные с Foxd3, обогащают через биотинированный Foxd3-Avi и стрептавидин, затем секвенируют. После выравнивания на GRCz11 получают BAM. Высокое локальное покрытие ChIP относительно контроля указывает на участок, где Foxd3 был обогащён.

Input — хроматин до специфического обогащения. Он отражает неравномерность фрагментации, картируемости, GC-состава и секвенирования. Input не контролирует весь возможный фон стрептавидиновой системы. Для этого в принципе полезен отдельный BirA-only контроль; в учебном workflow сравнение выполнено именно с Input.

2.3. Read, fragment, coverage и peak

В paired-end данных два рида соответствуют концам одного ДНК-фрагмента. В `bamCoverage` без `--extendReads` покрытие строится по выровненным ридам, тогда как MACS3 в режиме `-f BAMPE` восстанавливает реальные интервалы фрагментов между концами пары. Поэтому BigWig и pileup MACS3 описывают близкие, но не полностью одинаковые величины.

Peak — интервал, где ChIP-сигнал статистически превышает локальный фон. **Summit** — позиция максимального обогащения внутри пика. Один пик нельзя буквально считать одним сайтом связывания: соседние события могут сливаться, а слабые реальные сайты могут не пройти порог.

3. Единый workflow и смысл каждого шага

3.1. Контроль BAM

```
samtools flagstat data/foxd3_14ss_chip.nuclear.bam
samtools flagstat data/foxd3_14ss_input.nuclear.bam
```

`flagstat` считает записи BAM по флагам: mapped, properly paired, secondary, supplementary, duplicates и другие категории. Поскольку переданы уже отфильтрованные `*.nuclear.bam`, 100 % mapped и properly paired описывают состав готового файла, а не качество исходного FASTQ. Значение duplicates = 0 означает, что ни одна запись не помечена как дубликат; без знания этапа duplicate marking нельзя утверждать, что дубликатных молекул в исходной библиотеке не было.

3.2. Нормированное покрытие ChIP и Input

```
bamCoverage -b data/foxd3_14ss_chip.nuclear.bam   -o \
  results/signal/foxd3_14ss_chip.CPM.bw   --normalizeUsing CPM --binSize 10 \
  --numberOfProcessors 4

bamCoverage -b data/foxd3_14ss_input.nuclear.bam   -o \
  results/signal/foxd3_14ss_input.CPM.bw   --normalizeUsing CPM --binSize 10 \
  --numberOfProcessors 4
```

Геном делится на бины по 10 п.н.; для каждого бина вычисляется покрытие и масштабируется на миллион выравниваний. CPM устраняет простое различие глубины, но не делает библиотеки полностью эквивалентными: разные signal-to-noise, длины фрагментов и состав клеток сохраняются.

3.3. Дорожка $\log_2$(ChIP/Input)

```
bigwigCompare   -b1 results/signal/foxd3_14ss_chip.CPM.bw   -b2 \
  results/signal/foxd3_14ss_input.CPM.bw   --operation log2 --pseudocount 1 --binSize 10 \
  -o results/signal/foxd3_14ss.log2_IP_Input.bw
```

Для каждого бина вычисляется $S(x) = \log_2[(ChIP(x)+1)/(Input(x)+1)]$. Положительный S показывает преобладание ChIP, отрицательный — Input. Псевдосчёт предотвращает деление на ноль, но при малых CPM заметно сжимает отношение. Поэтому дорожка удобна для визуального поиска и направления эффекта, а не как точная оценка fold enrichment.

3.4. Вызов пиков MACS3

```
macs3 callpeak   -t data/foxd3_14ss_chip.nuclear.bam   -c \
  data/foxd3_14ss_input.nuclear.bam   -f BAMPE -g 1360000000 -n foxd3_14ss -q 0.01 \
  --outdir results/peaks
```

`-f BAMPE` заставляет MACS3 использовать интервалы paired-end фрагментов. `-g 1360000000` задаёт эффективный размер генома. При `-q 0.01` остаются пики с q-value ≤ 0,01. По умолчанию MACS3 масштабирует более глубокую библиотеку к меньшей (`--scale-to small`), что уменьшает риск искусственного усиления слабой библиотеки.

3.5. Полная последовательность команд для 75ep и 1–2ss

Команды ниже выполняются из `~/chipseq_seminar` в окружении семинара. Цикл создаёт одинаковые результаты для обеих домашних стадий. Перед запуском полезно проверить имена BAM через `ls data/75ep data/1-2ss`, потому что одна ошибка в дефисе меняет путь.

```
cd ~/chipseq_seminar
mkdir -p results/{qc,signal,peaks,figures,stage_comparison/sorted}

for s in 75ep 1-2ss; do
  chip=data/$s/foxd3_${s}_chip.nuclear.bam
  inp=data/$s/foxd3_${s}_input.nuclear.bam

  # 1. QC
  samtools flagstat $chip > results/qc/${s}_chip.flagstat.txt
  samtools flagstat $inp  > results/qc/${s}_input.flagstat.txt

  # 2. CPM BigWig для ChIP и Input
  bamCoverage -b $chip -o results/signal/foxd3_${s}_chip.CPM.bw     --normalizeUsing CPM \
    --binSize 10 -p 4
  bamCoverage -b $inp -o results/signal/foxd3_${s}_input.CPM.bw     --normalizeUsing CPM \
    --binSize 10 -p 4

  # 3. Обогащение ChIP относительно Input
```

```
  bigwigCompare     -b1 results/signal/foxd3_${s}_chip.CPM.bw     -b2 \
    results/signal/foxd3_${s}_input.CPM.bw     --operation log2 --pseudocount 1 \
    --binSize 10     -o results/signal/foxd3_${s}.log2_IP_Input.bw

  # 4. Peak calling
  macs3 callpeak -t $chip -c $inp -f BAMPE -g 1360000000     -n foxd3_${s} -q 0.01 \
    --outdir results/peaks

  wc -l results/peaks/foxd3_${s}_peaks.narrowPeak
  sort -k9,9nr results/peaks/foxd3_${s}_peaks.narrowPeak | head

  # 5. Read-based FRiP по схеме семинара
  total=$(samtools view -c $chip)
  inpk=$(samtools view -c -L     results/peaks/foxd3_${s}_peaks.narrowPeak $chip)
  awk -v s=$s -v a=$inpk -v b=$total     'BEGIN{printf \
    "%s\ttotal=%d\tin_peaks=%d\tFRiP=%.8f\n",s,b,a,a/b}'     | tee \
    results/qc/frip_${s}.tsv

  # 6. Матрица, heatmap и средний профиль
  computeMatrix reference-point --referencePoint center     -R \
    results/peaks/foxd3_${s}_summits.bed     -S results/signal/foxd3_${s}_chip.CPM.bw \
    results/signal/foxd3_${s}_input.CPM.bw     -b 2000 -a 2000 --binSize 20     -o \
    results/figures/foxd3_${s}.matrix.gz

  plotHeatmap -m results/figures/foxd3_${s}.matrix.gz     -out \
    results/figures/foxd3_${s}.heatmap.pdf     --samplesLabel "Foxd3 ChIP" "Input" \
    --refPointLabel summit --regionsLabel peaks     --xAxisLabel "distance to summit \
    (bp)"

  plotProfile -m results/figures/foxd3_${s}.matrix.gz     -out \
    results/figures/foxd3_${s}.profile.pdf     --samplesLabel "Foxd3 ChIP" "Input" \
    --refPointLabel summit --regionsLabel peaks
done
```

После цикла проверяют, что для каждой стадии существуют три BigWig, `narrowPeak`, `summits.bed`, `peaks.xls`, `matrix.gz`, heatmap, profile и файл FRiP. Наличие файла ещё не гарантирует корректность: нужно прочитать stderr/log программы, проверить ненулевой размер и открыть графики.

4. Как MACS3 оценивает значимость

4.1. Локальный фон и p-value

В каждой позиции наблюдается ChIP pileup k. MACS3 оценивает локальную интенсивность фона λ_{local} по Input и окружению разных масштабов, затем при нулевой гипотезе моделирует число фоновых фрагментов распределением Пуассона: $K \sim Poisson(\lambda_{local})$. p-value — вероятность получить k или больше фрагментов при одном фоне: $P(K \geq k \mid \lambda_{local})$. Чем меньше p-value, тем хуже данные согласуются с отсутствием обогащения.

4.2. Почему нужен q-value

Геном содержит миллионы проверяемых позиций, поэтому обычный порог $p < 0{,}05$ породил бы множество ложных находок. MACS3 корректирует p-value процедурой Benjamini–Hochberg. q-value можно понимать как минимальный уровень FDR, при котором результат попадёт в набор значимых. Порог $q \leq 0{,}01$ контролирует ожидаемую долю ложных открытий среди объявленных значимыми примерно на уровне 1 % при допущениях процедуры.

4.3. narrowPeak: десять колонок

№	Поле	Смысл
1	chrom	хромосома или скаффолд
2–3	start, end	0-based полуоткрытый интервал [start, end)
4	name	имя пика
5	score	целый score для браузера; в MACS3 может превышать диапазон UCSC 0–1000
6	strand	для обычного TF ChIP-seq цепь не определяется, обычно “.”
7	signalValue	fold enrichment в summit относительно локального фона
8	pValue	$-\log_{10}$(p-value)
9	qValue	$-\log_{10}$(q-value)
10	peak	смещение summit от start

Самые значимые пики ищут сортировкой по девятой колонке: `sort -k9,9nr ... | head`. Если девятая колонка равна 100,05, то $q \approx 10^{-100{,}05}$. Больший $-\log_{10}(q)$ означает более высокую статистическую значимость, но не обязательно большую биологическую силу: q зависит и от глубины библиотеки.

4.4. Метапрофиль и heatmap

```
computeMatrix reference-point --referencePoint center   -R \
  results/peaks/foxd3_14ss_summits.bed   -S results/signal/foxd3_14ss_chip.CPM.bw \
  results/signal/foxd3_14ss_input.CPM.bw   -b 2000 -a 2000 --binSize 20   -o \
  results/figures/foxd3_14ss.matrix.gz

plotHeatmap -m results/figures/foxd3_14ss.matrix.gz   -out \
  results/figures/foxd3_14ss.heatmap.pdf   --samplesLabel "Foxd3 ChIP" "Input" \
  --refPointLabel summit

plotProfile -m results/figures/foxd3_14ss.matrix.gz   -out \
  results/figures/foxd3_14ss.profile.pdf   --samplesLabel "Foxd3 ChIP" "Input" \
  --refPointLabel summit
```

Для каждой вершины берётся окно ±2 кб и делится на 200 бинов по 20 п.н. В `matrix.gz` одна строка соответствует одному пику, а столбцы содержат сигнал по позициям, сначала для ChIP, затем для Input. Heatmap показывает неоднородность отдельных пиков; average profile усредняет строки и отвечает на вопрос, есть ли типичный центральный максимум.

5. Результаты контроля качества

Стадия	Образец	Выравниваний	Пар	Mapped	Properly paired	Помечено duplicates
75ep	ChIP	23 863 894	11 931 947	100 %	100 %	0
75ep	Input	39 931 858	19 965 929	100 %	100 %	0
1–2ss	ChIP	12 816 614	6 408 307	100 %	100 %	0
1–2ss	Input	33 460 348	16 730 174	100 %	100 %	0
5–6ss	ChIP	18 853 396	9 426 698	—	—	—
5–6ss	Input	57 051 062	28 525 531	—	—	—
14ss	ChIP	41 553 880	20 776 940	100 %	100 %	0
14ss	Input	27 794 668	13 897 334	100 %	100 %	0

Табл. 2. Глубина BAM. Для 5–6ss в переданных материалах приведены глубины, но не полный вывод flagstat, поэтому не заполненные показатели не восстанавливаются предположением.

Input глубже ChIP в 1,67 раза для 75ep, 2,61 раза для 1–2ss и 3,03 раза для 5–6ss. На 14ss, напротив, ChIP глубже Input примерно в 1,50 раза. Поэтому абсолютные counts или ненормированное покрытие между ChIP и Input сравнивать нельзя.

Отсутствие secondary и supplementary записей и 100 % properly paired показывают, что BAM уже прошли жёсткую фильтрацию. Это удобно для учебного анализа, но не заменяет QC исходного выравнивания, распределения длины фрагментов, сложности библиотеки и оценки дубликатов до фильтрации.

Команды для двух домашних стадий

```
for s in 75ep 1-2ss; do
  samtools flagstat data/$s/foxd3_${s}_chip.nuclear.bam
  samtools flagstat data/$s/foxd3_${s}_input.nuclear.bam
done
```

6. Семинарская стадия 14ss

Для 14ss найдено 170 пиков при q ≤ 0,01. Самый значимый пик имеет $-\log_{10}(q) = 321{,}45$, то есть $q \approx 3{,}5\times10^{-322}$. Это чрезвычайно малая оценка q-value, но её нельзя интерпретировать как «в 3 раза более сильное связывание», чем при $-\log_{10}(q) = 100$: статистическая значимость растёт с числом наблюдений и качеством фона.

Показатель	14ss	Как получено
ChIP alignments	41 553 880	samtools view -c
Input alignments	27 794 668	samtools flagstat / view -c
Пиков	170	wc -l narrowPeak
Alignments в пиках	67 346	samtools view -c -L
Read-based FRiP	0,00162 = 0,162 %	67 346 / 41 553 880
Общих с 5–6ss	40 пиков 5–6ss	bedtools intersect -u
14ss без пересечения с 5–6ss	130	bedtools intersect -v

Метапрофиль 14ss имеет центральный максимум ChIP, но Input также показывает центральный бугор. Поэтому часть среднего профиля отражает высокофоновые или картируемые области. Для интерпретации важны не только средняя кривая, но и строки heatmap, signalValue MACS3 и визуальная проверка IGV.

Почему 170 пиков — не 170 молекулярных сайтов

- Порог q = 0,01 отсекает слабые события.
- Соседние события могут объединиться в один интервал.
- В ткани смешаны разные типы клеток, и клеточно-специфичное связывание разбавляется.
- Ширина и число пиков зависят от локального фона и параметров peak calling.

7. Домашние стадии 75ep и 1–2ss

7.1. Пики и наиболее значимые области

Показатель	75ep	1–2ss
Пиков при q ≤ 0,01	36	40
Максимальный $-\log_{10}(q)$	100,05	56,18
q-value сильнейшего по значимости пика	$\approx 8{,}9\times10^{-101}$	$\approx 6{,}6\times10^{-57}$
signalValue этого пика	21,7	21,2
Расположение	chr2:33 276 014–33 276 551	тот же локус chr2

Сильнейшие пики ранних стадий частично совпадают: среди топ-10 общими являются области на chr2, chr4, chr6, chr16 и chr12. Это говорит о воспроизводимом ядре сильных локусов, но само по себе не доказывает функциональность и не заменяет биологические повторы.

7.2. FRiP

```
total=$(samtools view -c $bam)
inpk=$(samtools view -c -L results/peaks/foxd3_${s}_peaks.narrowPeak $bam)
awk -v a=$inpk -v b=$total 'BEGIN{print a/b}'
```

Стадия	ChIP alignments	Alignments в пиках	FRiP	FRiP, %
75ep	23 863 894	4 101	0,00017185	0,0172
1–2ss	12 816 614	1 799	0,00014037	0,0140
5–6ss	18 853 396	≈44 500	0,00236	0,236
14ss	41 553 880	67 346	0,0016207	0,162

FRiP здесь вычислен так, как задано на семинаре: по BAM-записям, то есть по ридам. В paired-end данных стандартный fragment-based FRiP можно считать по фрагментам; у границ пиков он может немного отличаться. Сравнение FRiP между стадиями также не полностью нейтрально: большая совокупная длина и большее число пиков сами по себе увеличивают долю библиотеки, которая может попасть в пики.

7.3. Метапрофили

75ep показывает центральный ChIP-пик примерно 1,4 CPM, но Input тоже повышен в центре примерно до 0,7 CPM. Среднее чувствительно к нескольким высокофоновым строкам. Для 1–2ss абсолютный ChIP-сигнал ниже, но центральный контраст относительно Input визуально чище — приблизительно 4–5 против 2 для 75ep.

8. Heatmap и average profile

8.1. Стадия 75ep

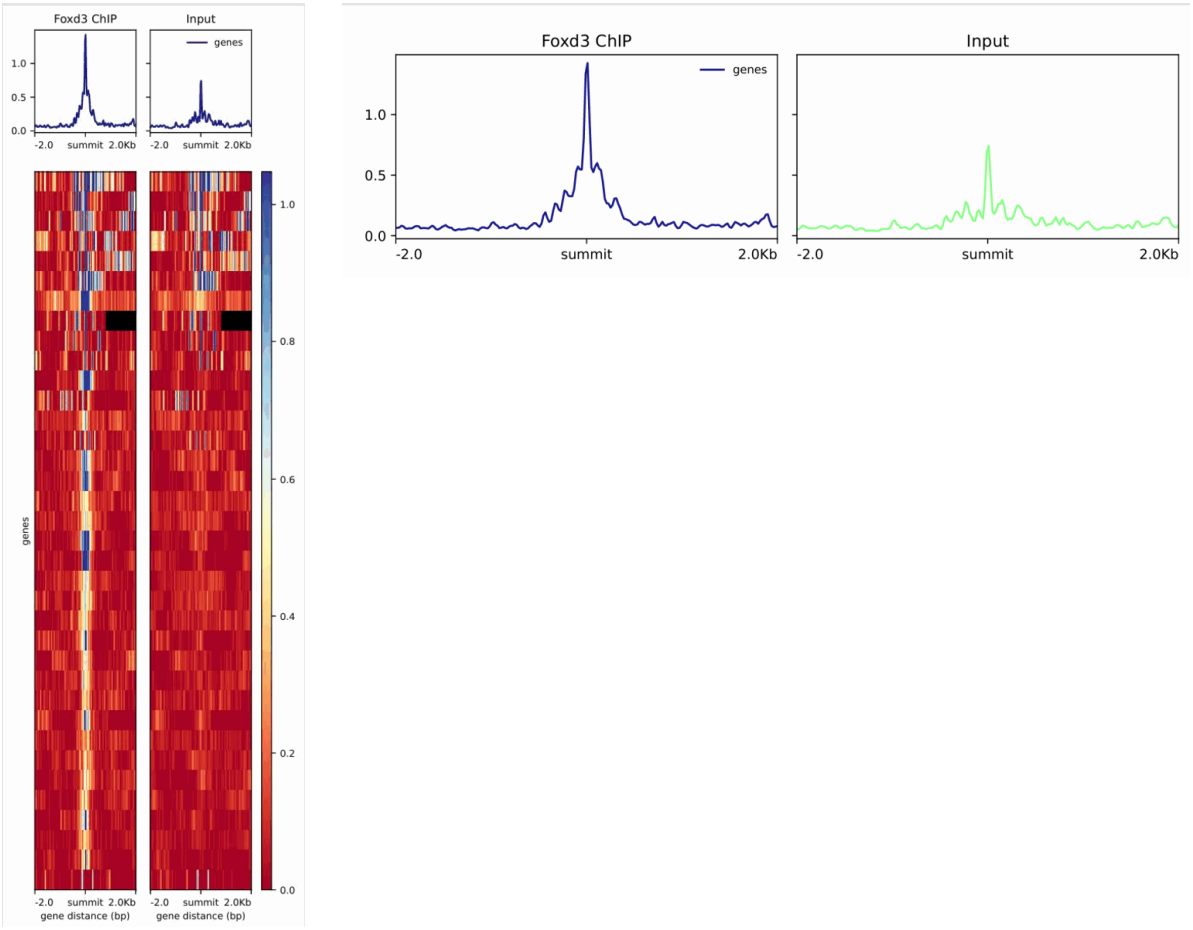
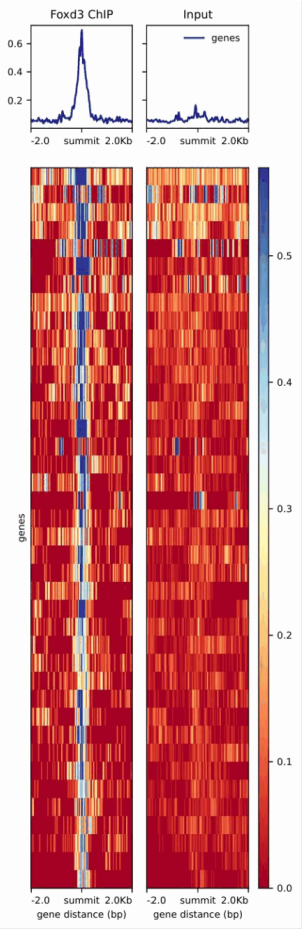


Рис. 2. Heatmap и средний профиль 75ep вокруг summit ±2 кб. Чёрная область соответствует отсутствующим значениям для окна, выходящего за край последовательности.

Вертикальная центральная полоса ChIP подтверждает локальное обогащение. Одновременно заметный центральный Input и яркие протяжённые строки указывают, что часть пиков лежит в участках повышенного фонового покрытия. Поэтому средний профиль нельзя читать без heatmap.

8.2. Стадия 1–2ss



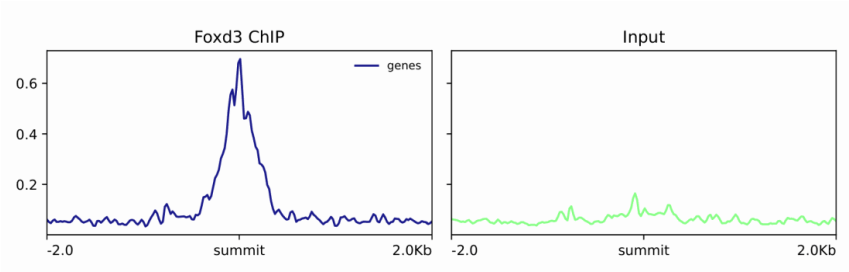


Рис. 3. Heatmap и средний профиль 1–2ss. Центральный ChIP-сигнал выражен у большинства строк, тогда как Input остаётся ниже.

Подписи `genes` и `gene distance (bp)` в исходных графиках — стандартные подписи deepTools и не соответствуют смыслу данных: строками являются пики, а x — расстояние до summit. В повторном построении следует добавить `--regionsLabel peaks --xAxisLabel "distance to summit (bp)"`.

8.3. Сопоставление всех стадий

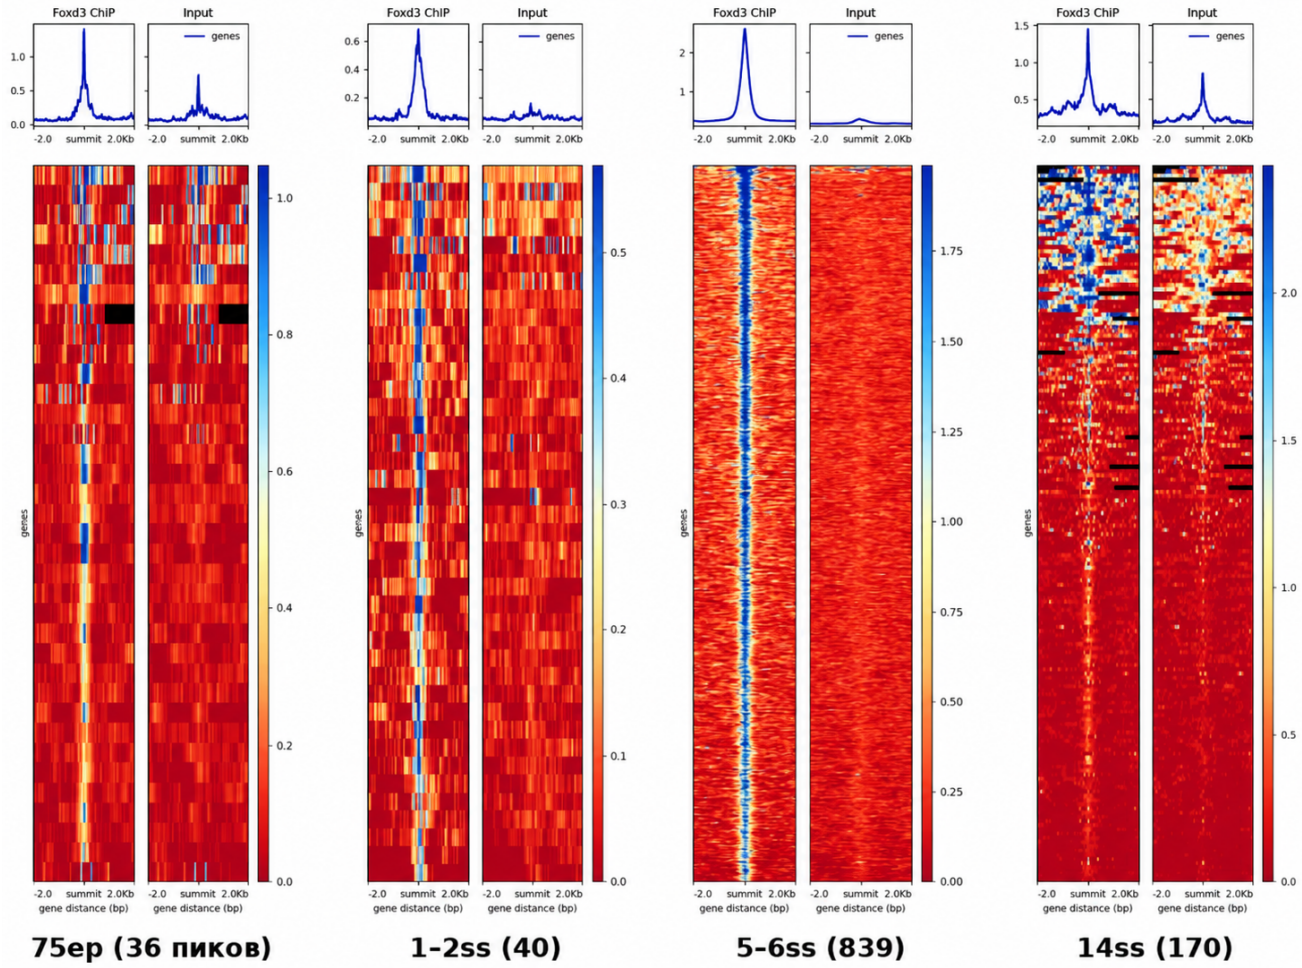


Рис. 4. Исходные heatmap и профили четырёх стадий. Цветовые шкалы и пределы оси Y различаются, поэтому прямое сравнение интенсивности цвета некорректно.

Качественно наиболее чистый центральный контраст наблюдается для 5–6ss. Для строгого сравнения следует перестроить панели с общей шкалой, одинаковыми настройками `bamCoverage`, одинаковым набором опорных регионов и желательно по объединённому consensus peak set. Если каждая стадия центрируется по собственным пикам, профиль отвечает на вопрос «как выглядит сигнал в найденных здесь пиках», но не сравнивает одни и те же локусы между стадиями.

Рекомендуемая команда для сопоставимых панелей добавляет одинаковые `--zMin/--zMax`, `--yMin/--yMax`, явные подписи и одинаковый способ усреднения. Однако одинаковая шкала не исправляет различия обработки исходных BigWig; параметры 5–6ss следует сначала проверить по командным логам или заголовку `peaks.xls`.

9. Сравнение четырёх стадий

9.1. Сводная таблица

Стадия	ChIP, млн	Input, млн	Input/ChIP	Пиков	FRiP, %	max $-\log_{10}(q)$	FE сильнейшего по q
75ep	23,86	39,93	1,67	36	0,017	100,05	21,7
1–2ss	12,82	33,46	2,61	40	0,014	56,18	21,2
5–6ss	18,85	57,05	3,03	839	0,236	163,70	нет в переданных сводках
14ss	41,55	27,79	0,67	170	0,162	321,45	25,0

Табл. 3. Основные численные результаты. Пропуск для FE 5–6ss оставлен честно: его нельзя восстановить из представленных PDF без narrowPeak.

9.2. Число пиков

Последовательность 36 → 40 → 839 → 170 показывает резкий максимум на 5–6ss. Простая глубина ChIP не объясняет этот максимум: 5–6ss содержит меньше ChIP-выравниваний, чем 75ep и 14ss, но намного больше пиков. Это сильный аргумент в пользу биологического расширения детектируемого связывания к спецификации нервного гребня.

Тем не менее число пиков не является чистой биологической величиной. Оно зависит от signal-to-noise, глубины и качества Input, параметров MACS3, ширины фрагментов, фильтрации скаффолдов и наличия повторов. Поэтому корректная формулировка — «при данном workflow детектируется 839 пиков», а не «Foxd3 имеет ровно 839 сайтов».

9.3. FRiP

FRiP повторяет общий максимум 5–6ss и остаётся повышенным на 14ss. Однако FRiP объединяет как минимум два эффекта: концентрацию ChIP-сигнала и суммарную длину вызванных пиков. При 839 пиках больше геномной территории входит в числитель, чем при 36 пиках. Для межстадийного сравнения полезно дополнить FRiP анализом signalValue, профилем на общем consensus peak set и downsampling.

9.4. Сила обогащения и статистическая значимость

Сильнейшие по q пики на 75ep, 1–2ss и 14ss имеют похожий signalValue порядка 21–25, хотя $-\log_{10}(q)$ различается от 56 до 321. Это наглядно показывает, что q-value и fold enrichment отвечают на разные вопросы. Высокая значимость 14ss совместима с большей глубиной ChIP и более точной оценкой статистики; приписать её только биологии или только глубине без downsampling нельзя.

10. Попарные перекрытия и индекс Жаккара

10.1. Команды

```
sort -k1,1 -k2,2n A.narrowPeak > A.sorted.bed
sort -k1,1 -k2,2n B.narrowPeak > B.sorted.bed

bedtools intersect -a A.sorted.bed -b B.sorted.bed -u | wc -l
bedtools intersect -a A.sorted.bed -b B.sorted.bed -v | wc -l
bedtools jaccard  -a A.sorted.bed -b B.sorted.bed
```

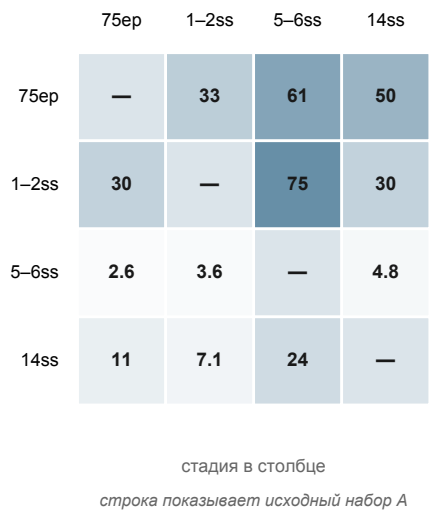
`intersect -u` отвечает асимметрично: какая доля интервалов A имеет хотя бы одно пересечение с B. Перестановка A и B может изменить число. По умолчанию достаточно 1 п.н. пересечения; для биологически строгого анализа стоит проверить устойчивость результата при минимальной доле перекрытия (`-f`) и взаимном условии (`-r`).

`bedtools jaccard` сравнивает длину пересечения и объединения геномных интервалов. Это base-pair metric, а не отношение числа общих пиков к числу всех пиков. Значение особенно уменьшается, когда размеры наборов сильно различаются.

Пара	Пики A→B	Доля A	Пики B→A	Доля B	Jaccard
75ep / 1–2ss	12/36	33 %	12/40	30 %	0,174
75ep / 5–6ss	22/36	61 %	22/839	2,6 %	0,023
75ep / 14ss	18/36	50 %	18/170	11 %	0,075
1–2ss / 5–6ss	30/40	75 %	30/839	3,6 %	0,028
1–2ss / 14ss	12/40	30 %	12/170	7,1 %	0,043
5–6ss / 14ss	40/839	4,8 %	40/170	24 %	0,037

Табл. 4. Направленные доли перекрытия и Jaccard. Стрелка A→B означает: доля пиков A, которые задевают хотя бы один пик B.

а. Доля пиков A, пересекающих B, %



б. Индекс Жаккара по длине интервалов

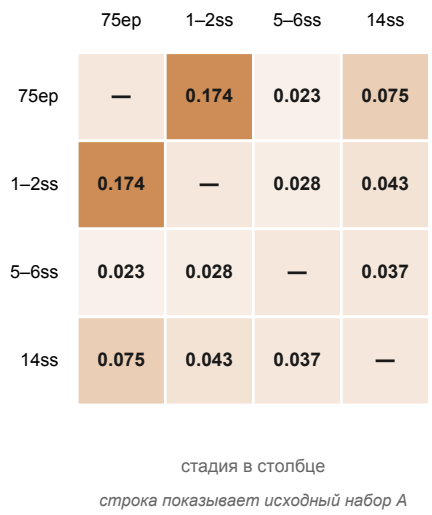


Рис. 5. Две взаимодополняющие меры сходства. Направленная доля показывает вложенность небольшого набора; Jaccard учитывает длину интервалов и объединение.

11. Как читать межстадийные перекрытия

11.1. Ранние пики как подмножество программы 5–6ss

С 5–6ss пересекаются 61 % пиков 75ep и 75 % пиков 1–2ss. Направленное перекрытие высоко, хотя Jaccard низок, потому что набор 5–6ss намного больше. Следовательно, корректный вывод такой: значительная доля ранних пиков сохраняется или вновь обнаруживается на 5–6ss, а одновременно на 5–6ss появляется множество дополнительных пиков.

11.2. Переход 5–6ss → 14ss

Только 40 из 839 пиков 5–6ss пересекают пики 14ss (4,8 %), тогда как 40 из 170 пиков 14ss пересекают набор 5–6ss (24 %). Таким образом, большая часть программы 5–6ss к 14ss не детектируется, а большинство пиков 14ss не совпадает с 5–6ss. Это самая заметная перестройка репертуара в данных.

11.3. Pairwise-specific и truly stage-specific — разные понятия

Значения 799 и 130 относятся только к одной паре: 799 пиков 5–6ss не пересекают 14ss, а 130 пиков 14ss не пересекают 5–6ss. Их нельзя автоматически называть уникальными среди всех четырёх стадий: часть может пересекать 75ep или 1–2ss.

Стадия	Всего	Минимум pairwise-only по таблице	Что можно честно сказать без BED всех стадий
75ep	36	≤14	точное число уникальных для всех четырёх не приведено
1–2ss	40	≤10	точное число уникальных для всех четырёх не приведено
5–6ss	839	≤799	799 специфичны только относительно 14ss
14ss	170	≤130	130 специфичны только относительно 5–6ss

Точные truly stage-specific наборы вычисляются одной командой с тремя файлами в `-b`. В переданных PDF результат этой команды отсутствует, поэтому в настоящем отчёте верхние оценки не подменяются точными значениями.

```
bedtools intersect -a 75ep.sorted.bed   -b 1-2ss.sorted.bed 5-6ss.sorted.bed \
  14ss.sorted.bed   -v > only_75ep.bed
```

11.4. Почему нельзя объявить перекрытия неслучайными без теста

Совпадение сильных локусов выглядит убедительно, но формальная значимость зависит от доступной для пиков части генома, ширины интервалов, картируемости и кластеризации регуляторных элементов. Для строгой проверки применяют `bedtools fisher` или перестановочный тест с matched background. Поэтому формулировка «случайное совпадение исключено» заменена на «перекрытие поддерживает наличие общего ядра и требует формальной проверки».

12. Визуализация в IGV

В IGV загружены референс GRCz11, GTF, ChIP CPM, Input CPM, $\log_2$(ChIP/Input) и пики. При разных автоматических шкалах нельзя сравнивать высоту дорожек «на глаз»; сначала нужно читать числовой предел шкалы. Для межстадийного сравнения желательно фиксировать одинаковые пределы хотя бы для однотипных дорожек.

12.1. Сильный пик 5–6ss: chr6:32 203 000–32 210 000

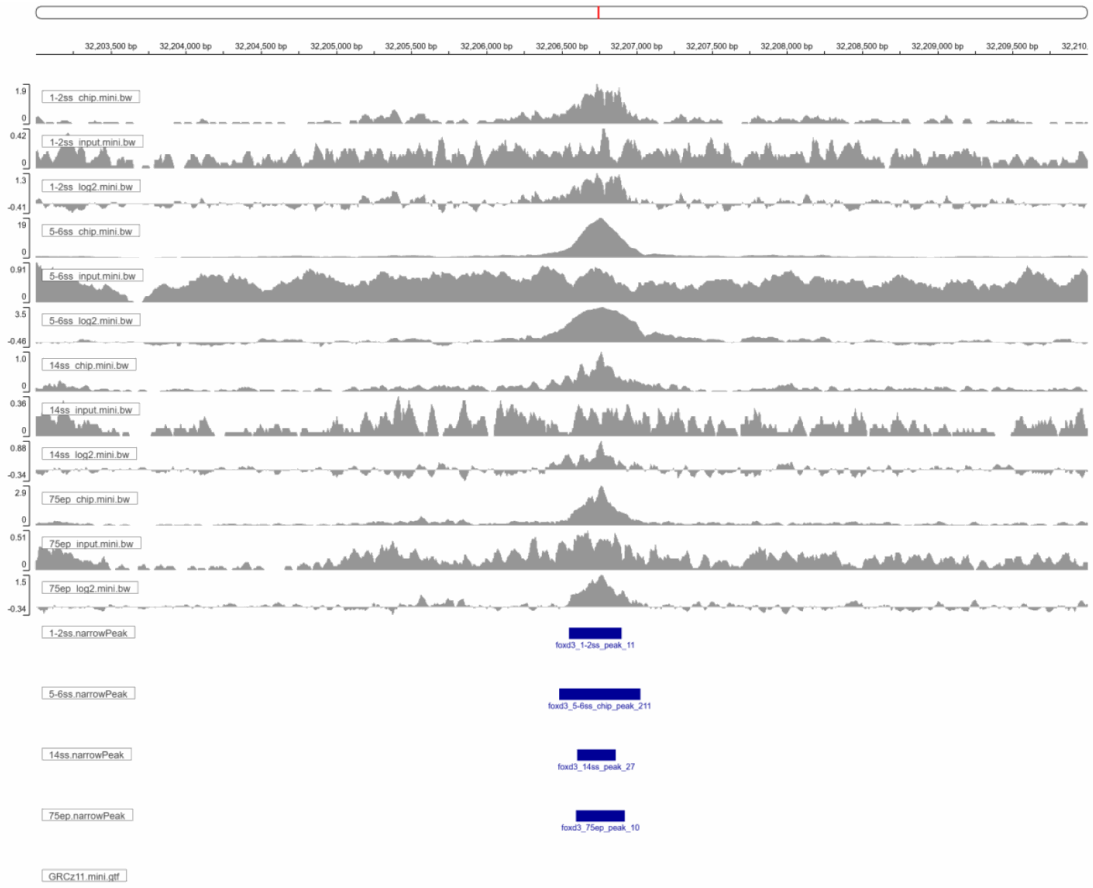


Рис. 6. Локус NC_007117.7 около 32,207 Мб. Пик детектируется на всех стадиях, но наиболее выражен на 5–6ss.

Вершина расположена около 32 206 750. На 75ep и 1–2ss локус входит в число наиболее значимых, а на 5–6ss сигнал резко усиливается. Участок находится примерно в 113 кб от foxd3 и по положению согласуется с регуляторным локусом, показанным в статье. Без прямого сопоставления координат с аннотацией статьи его следует называть вероятным, а не доказанным элементом enh6.

12.2. Общий локус: chr2:33 272 000–33 280 000

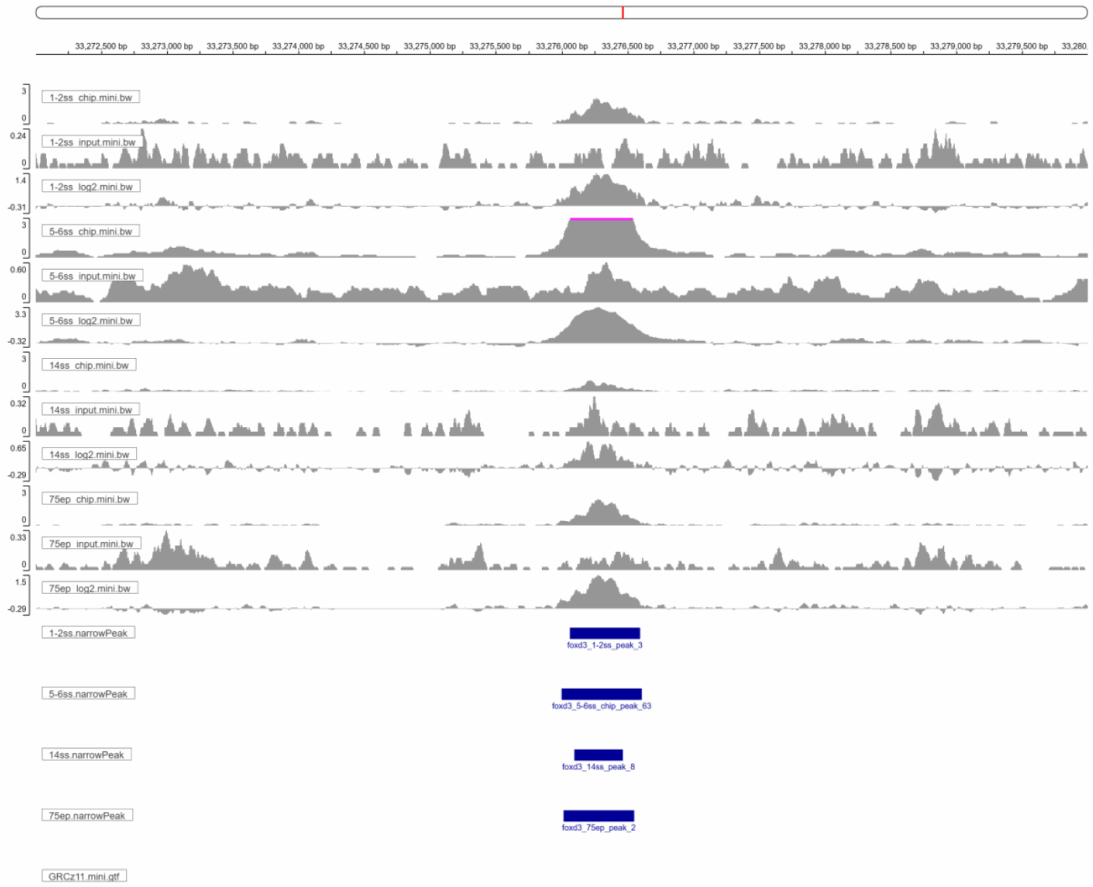


Рис. 7. Локус NC_007113.7 около 33,276 Мб. Пик присутствует на четырёх стадиях, но амплитуда различается.

На 75ep и 1–2ss это самый значимый пик, signalValue около 21. На 14ss он слабее (FE около 5,5), а на 5–6ss заметно усиливается. Пример показывает, почему бинарная матрица «есть/нет пика» теряет информацию: один и тот же локус может сохраняться, но менять силу связывания.

12.3. Резко stage-biased локус: chr1:256 000–264 000

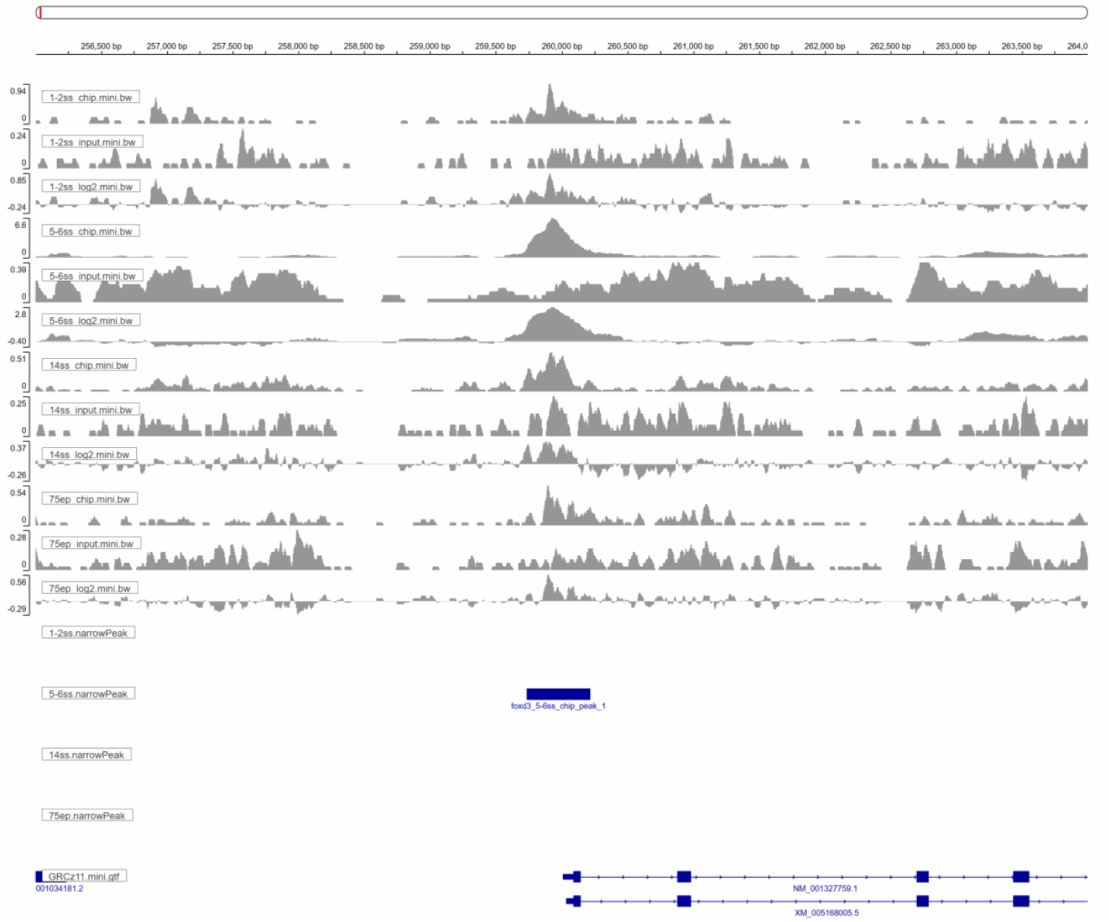


Рис. 8. Локус NC_007112.7 около 260 кб. Пик вызван только на 5–6ss; на других стадиях виден слабый подпороговый сигнал.

Пик 5–6ss перекрывает 5′-область транскрипта NM_001327759.1 / XM_005168005.5 и выглядит промоторным. Термин stage-biased точнее, чем абсолютно stage-specific: отсутствие вызванного пика на других стадиях означает непрохождение порога, а не строгое отсутствие связывания.