Домашнее задание 1. Ампликонный анализ 16S rRNA: данные mice и soil

Логика анализа

FASTQ (сырые риды) → импорт в QIIME 2 (.qza) → DADA2: фильтрация по качеству, исправление ошибок секвенирования, склейка пар (только для парных данных), удаление химер → таблица ASV × образцы и последовательности ASV → таксономия (классификатор Greengenes2) → филогенетическое дерево ASV → альфа-разнообразие (внутри образца) и бета-разнообразие (между образцами).

Файлы .qza — данные для следующих шагов; .qzv — визуализации, которые открываются на view.qiime2.org. ASV — точная последовательность ампликона, которую DADA2 считает реальной, а не ошибкой прибора; это не вид бактерии, а вариант участка гена.

Задача 1. Анализ данных mice и FastQC почвенного образца

1A.1. Дизайн эксперимента: что за мыши

В столбце group метаданных четыре группы:

Код	Кто это	n
L (Lab)	Обычные лабораторные мыши C57BL/6 со своей лабораторной микробиотой	8
LR (LabR)	C57BL/6, полученные от стерильных (germ-free) самок, которым пересадили микробиоту лабораторных мышей, — контроль самой процедуры пересадки	7
W (Wild)	Дикие домовые мыши (Mus musculus domesticus), пойманные в природе	7
WR (WildR)	C57BL/6, полученные от стерильных самок, которым пересадили микробиоту диких мышей: лабораторные мыши с «дикой» микробиотой	7

Итого 29 образцов; у каждого два FASTQ-файла (R1 и R2), поэтому в FastQC 58 файлов.

Если пересадка работает, WR по составу микробиоты должны быть ближе к W, а LR — к L. Главное различие ожидается между лабораторной и дикой микробиотой; различие «родные против пересаженных» — вторичное.

В первой версии отчёта было написано, что суффикс R не расшифровывается. Расшифровка есть в материалах семинара: WR — это лабораторные мыши с пересаженной микробиотой, а не дикие мыши.

1A.2. Контроль качества сырых ридов (FastQC + MultiQC)

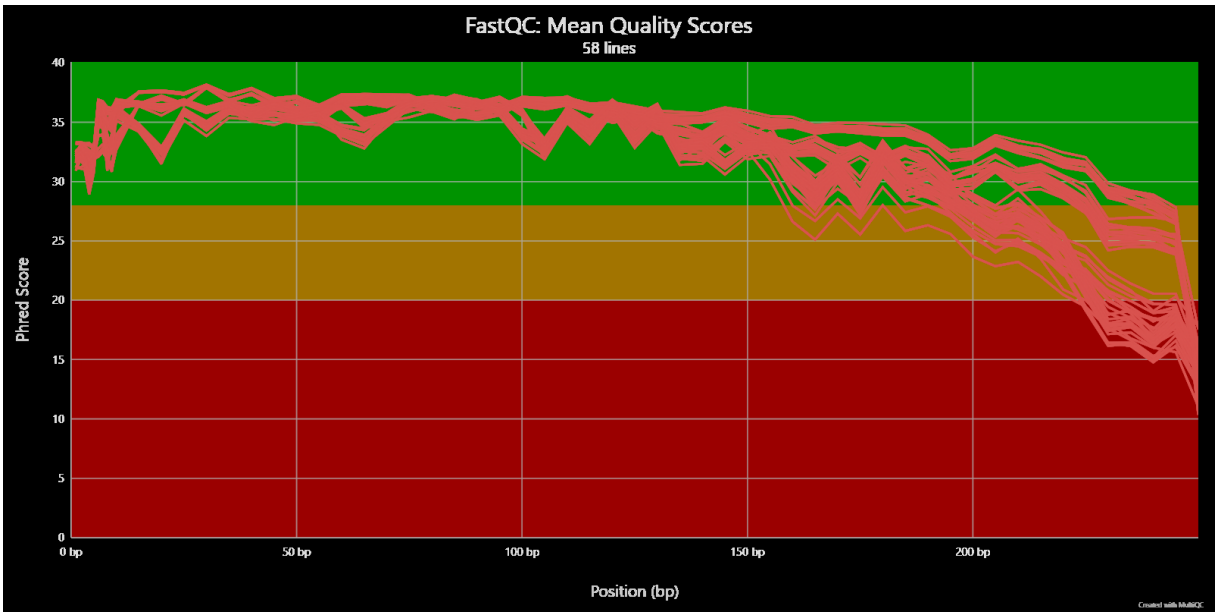


Рис. 1. MultiQC: средний Phred по позициям для 58 FASTQ-файлов (29 образцов × R1 и R2).

Каждая линия — один файл. Phred 30 означает вероятность ошибки 1/1000, Phred 20 — 1/100. Зелёная зона ≥ 28, жёлтая 20–28, красная < 20. Красный цвет самих линий — статус FAIL: FastQC ставит его, если хотя бы в одной позиции качество ниже порога. Для ампликонов с плохими хвостами это обычное дело и не повод выбрасывать данные: хвосты отрезаются в DADA2.

До ≈ 150 п.н. все файлы в зелёной зоне (Q ≈ 33–37). Дальше линии расходятся на два пучка: верхний держится выше Q28 почти до 230 п.н., нижний после ≈ 220 п.н. уходит ниже Q20. Сравнение с графиком QIIME 2 (рис. 5) показывает, что нижний пучок — обратные риды R2: у Illumina обратное чтение обычно хуже.

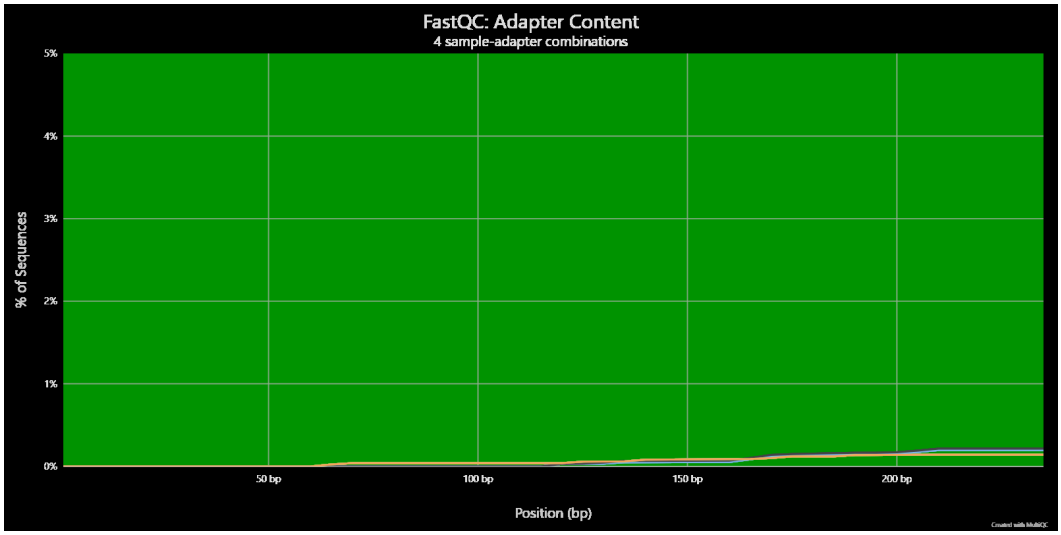


Рис. 2. Доля адаптерных последовательностей по позициям.

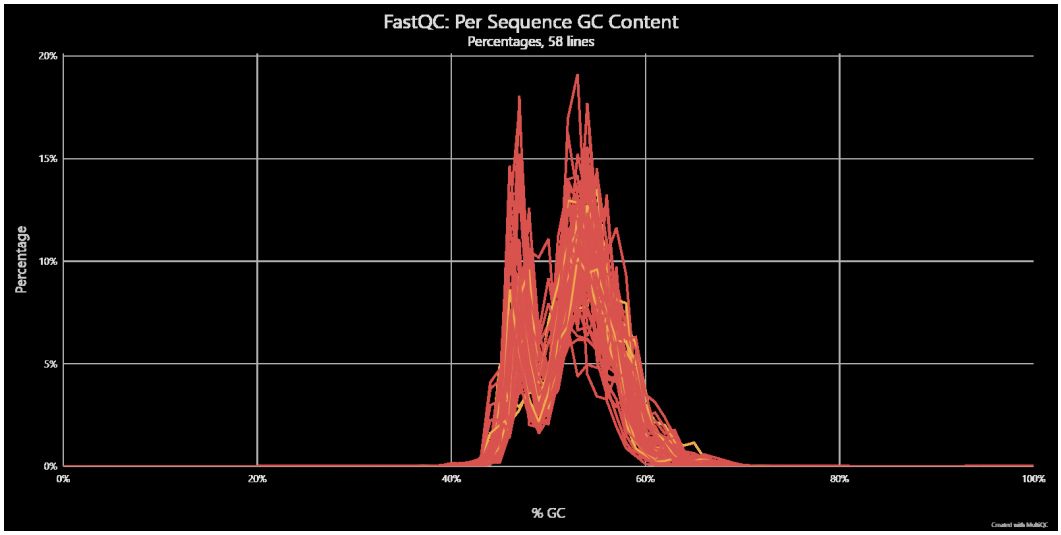


Рис. 3. Распределение GC-состава по ридам.

Адаптеры: доля ридов, в которых найден адаптер начиная с данной позиции. Здесь она не превышает ≈ 0,25%: ампликон (≈ 290 п.н.) длиннее рида (250 п.н.), поэтому секвенатор не дочитывает до адаптера. GC-состав: сколько ридов имеют данный процент G+C. У генома одного организма получается один «колокол», и FastQC сравнивает кривую с ним; в ампликоне смешаны разные бактерии, поэтому пиков может быть несколько. Здесь два пика — ≈ 47% и ≈ 54%.

Для ампликонных данных FastQC почти всегда ставит FAIL в разделах Per base sequence content, Per sequence GC content и Sequence duplication levels: все риды — копии одного гена и начинаются с одинакового участка. Это свойство метода, а не дефект данных.

Скриншот 1. Per base sequence content для одного файла mice (отдельно R1 и R2). Что на нём должно быть видно: если первые ≈ 19 позиций R1 заняты почти на 100% одним нуклеотидом и читаются как GTGCCAGC…, значит праймер остался в ридах и нужен trim-left-f 19 / trim-left-r 20; если состав «пёстрый» с первой позиции — праймеры уже удалены и trim-left 0 верен. Для почвы такой график есть (рис. 20), и праймер на нём виден хорошо.

Качество хорошее, адаптеров практически нет. Единственная проблема — падение качества к концу ридов, сильнее у R2. Решение — асимметричное усечение (trunc-len) в DADA2: R2 режем короче, чем R1.

1A.3. Импорт и сводка ридов

Demultiplexed sequence counts summary

	forward reads	reverse reads
Minimum	2138	2138
Median	4918.0	4918.0
Mean	4643.862069	4643.862069
Maximum	6394	6394
Total	134672	134672

Рис. 4. Сводка числа прочтений после импорта.

В R1 и в R2 по 134 672 рида: 29 образцов, в среднем 4 644 пары на образец (минимум 2 138, медиана 4 918, максимум 6 394). Числа для R1 и R2 должны совпадать — у каждого прямого рида есть пара; несовпадение означало бы повреждённые или перепутанные файлы. Глубина небольшая (тысячи, а не десятки тысяч ридов на образец), поэтому редкие ASV могут не попасть в выборку.

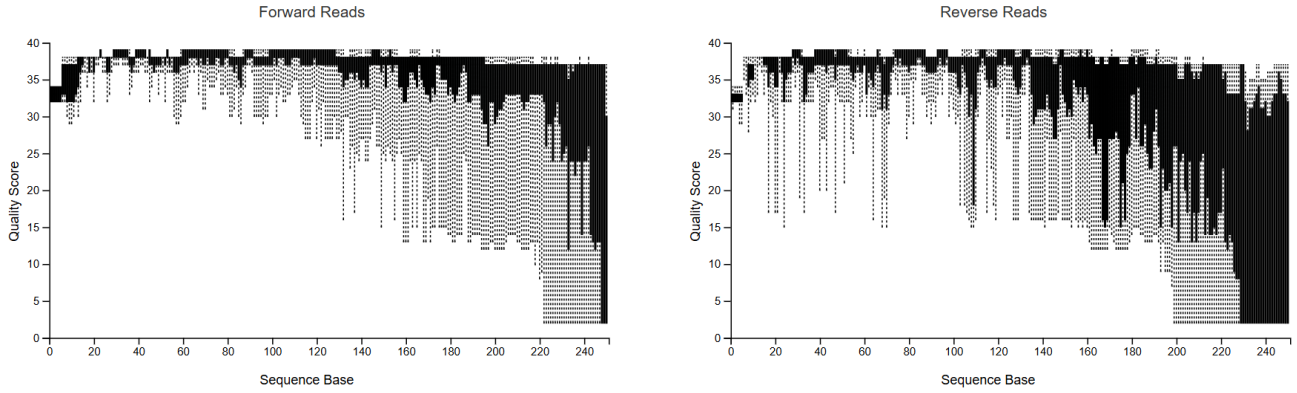


Рис. 5. График качества QIIME 2 (demux summarize): распределение Phred в каждой позиции для R1 (слева) и R2 (справа).

Для каждой позиции нарисован «ящик с усами»: линия внутри — медиана, ящик — средние 50% ридов, усы — почти весь разброс. Позицию для trunc-len выбирают там, где нижний край ящика начинает уходить вниз (ниже ≈ 25–30), но так, чтобы R1 и R2 после усечения всё ещё перекрывались.

Прямые риды держат высокое качество примерно до 200 п.н., затем ящики быстро расширяются вниз. Обратные портятся раньше: разброс заметно растёт уже после ≈ 160 п.н., а после ≈ 200 п.н. усы доходят до Q 2–10. Выбраны параметры trunc-len-f 180, trunc-len-r 150, trim-left 0.

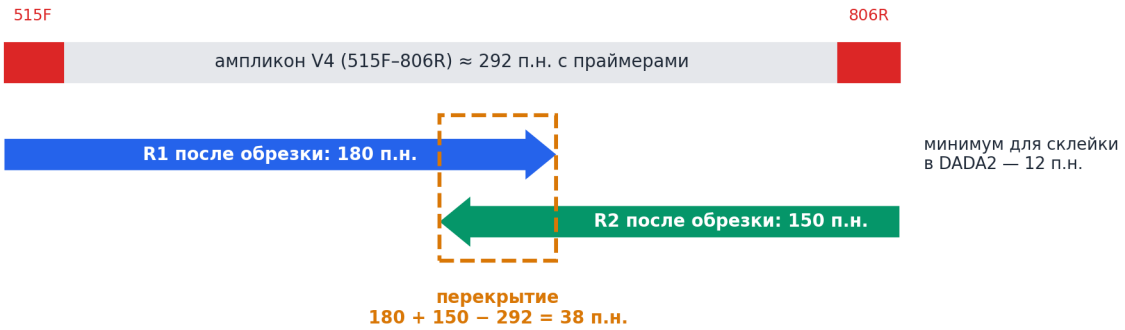


Рис. 6. Проверка перекрытия. Если праймеры в ридах не содержатся, ампликон короче (≈ 253 п.н.) и перекрытие больше (≈ 77 п.н.).

1A.4. DADA2: сколько ридов дошло до конца

sample-id #q2:types	input numeric	filtered numeric	percentage of input passed filter numeric	denoised numeric	merged numeric	percentage of input merged numeric	non-chimeric numeric	percentage of input non-chimeric numeric
L1	3773	3491	92.53	3375	2764	73.26	2725	72.22
L2	3669	3308	90.16	3192	2511	68.44	2511	68.44
L3	5346	4962	92.82	4843	3966	74.19	3575	66.87
L4	3836	3480	90.72	3370	2742	71.48	2663	69.42
L5	3311	3046	92	2924	2252	68.02	2181	65.87
L6	4572	4163	91.05	4016	3204	70.08	3104	67.89
L7	4536	4159	91.69	4049	3304	72.84	3249	71.63
L8	3498	3128	89.42	3030	2352	67.24	2352	67.24
LR1	5047	4777	94.65	4627	3919	77.65	3900	77.27
LR2	6394	6032	94.34	5914	4886	76.42	4770	74.6
LR3	5753	5383	93.57	5239	4105	71.35	3995	69.44
LR4	6062	5664	93.43	5507	4378	72.22	4355	71.84
LR5	6056	5608	92.6	5485	4630	76.45	4608	76.09
LR6	5855	5479	93.58	5360	4513	77.08	4513	77.08

Рис. 7. Статистика DADA2 (видна часть таблицы: группы L и LR).

Столбцы идут по порядку стадий: input — сколько пар было; filtered — прошли фильтр качества после усечения; denoised — прошли исправление ошибок; merged — R1 и R2 склеились в одну последовательность; non-chimeric — остались после удаления химер (искусственных гибридов двух последовательностей, возникающих в ПЦР). Столбцы «percentage of input …» — доля от исходного числа.

Пример L1: 3 773 → 3 491 (92,5%) → 3 375 → 2 764 (73,3%) → 2 725 (72,2%). В видимой части таблицы фильтр проходят 89–95% пар, а до конца доходят 66–77%. Больше всего теряется на склейке (−15–25% от denoised), на химерах — от 0 до ≈ 10% (L3: 3 966 → 3 575).

Почему теряется на склейке: перекрытие всего 38 п.н., и пара не склеивается, если в зоне перекрытия есть несовпадения или если у части бактерий ампликон немного длиннее. Прямые риды хороши примерно до 200 п.н., поэтому trunc-len-f 200 дал бы перекрытие ≈ 58 п.н. и, вероятно, меньше потерь — это можно упомянуть как возможное улучшение.

Для парных данных нормально сохранить больше половины ридов; ≈ 70% — хороший результат. У L (66–72%) и LR (69–77%) доли близки; при пролистывании таблицы у W и WR они должны быть того же порядка — тогда фильтрация не создаёт перекоса между группами.

1A.5. Таблица ASV и выбор глубины разрежения

Table summary

Summary Statistic	Value
Number of samples	29
Number of features	495
Total frequency	96 843

Рис. 8. Общая сводка таблицы ASV после DADA2.

Frequency per sample

	Frequency
Minimum frequency	1 490
1st quartile	2 598
Median frequency	3 516
3rd quartile	3 971
Maximum frequency	4 770
Mean frequency	3 339,4

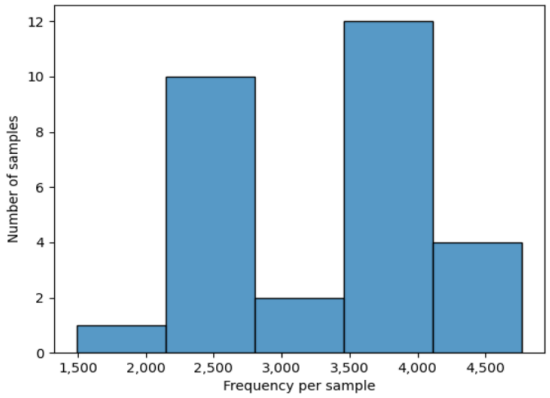


Рис. 9. Число ридов на образец в итоговой таблице.

Показатель	Значение
Образцов / уникальных ASV / всего ридов	29 / 495 / 96 843
Ридов на образец	минимум 1 490; Q1 2 598; медиана 3 516; Q3 3 971; максимум 4 770; среднее 3 339,4
Отношение максимум / минимум	≈ 3,2

Метрики разнообразия зависят от глубины: в глубоком образце найдётся больше редких ASV. Поэтому перед их расчётом все образцы разрежают — случайно берут из каждого одинаковое число ридов (--p-sampling-depth); образцы, где ридов меньше порога, выбрасываются.

Порог 1 490 — минимальная глубина, поэтому сохраняются все 29 животных (в каждой группе их всего 7–8). Цена — из глубоких образцов используется только часть ридов, и самые редкие ASV могут потеряться. Порог, например, 2 500 дал бы более точные оценки, но выбросил бы часть образцов.

1A.6. Таксономическая классификация

Feature ID #q2:types	Taxon categorical	Confidence categorical
001ea74b39dc57e51aa0f6c2ab1c475b	d__Bacteria; p__Firmicutes_A; c__Clostridia_258483; o__Lachnospirales; f__Lachnospiraceae; g__Paralachnospira; s__Paralachnospira sp902363445	0.9999182703243472
003a296ba4c55f34d62c224bda66f5a9	d__Bacteria; p__Firmicutes_A; c__Clostridia_258483; o__Oscillospirales; f__Oscillospiraceae_88309; g__Enterenecus; s__Enterenecus sp004560375	0.9993883674355829
00cd2f6860312475904748780758 9f27	d__Bacteria; p__Firmicutes_A; c__Clostridia_258483; o__Lachnospirales; f__Lachnospiraceae; g__1XD42-69; s__1XD42-69 sp009911505	0.9999999255006627
021b898345f1a2b66c1e0da5f63a93c6	d__Bacteria; p__Firmicutes_A; c__Clostridia_258483; o__Oscillospirales; f__Acutalibacteraceae; g__Acutalibacter; s__Acutalibacter sp009936055	0.999792696083565
02408cd609a6b7f8134da2f8955136ac	d__Bacteria; p__Bacteroidota; c__Bacteroidia; o__Bacteroidales; f__Muribaculaceae	0.9802995502514597
03a1f9f63e2fa6c7bdf27d33eba2b09d	d__Bacteria; p__Firmicutes_A; c__Clostridia_258483; o__Lachnospirales; f__Lachnospiraceae	0.9999913233262114
03ad6281e55a5d2f7eb1a7f44a2d0fd5	d__Bacteria; p__Bacteroidota; c__Bacteroidia; o__Bacteroidales; f__Rikenellaceae; g__Rikenella; s__Rikenella microfusus	0.9999600110313545
0438a5ba138f16c681d2a5ebd323d643	d__Bacteria; p__Firmicutes_A; c__Clostridia_258483; o__Lachnospirales; f__Lachnospiraceae	0.999994803483454
045acd620c390c80b3447bae8b6a039b	d__Bacteria; p__Firmicutes_A; c__Clostridia_258483; o__Oscillospirales; f__Oscillospiraceae_88309; g__Dysosmobacter; s__Dysosmobacter welbionis	0.931518904188007
04611dabe3583caf155167674ef7e0e4	d__Bacteria; p__Firmicutes_A; c__Clostridia_258483; o__Christensenellales; f__CAG-314; g__CAG-314; s__CAG-314 sp900551395	0.99999999988016
04bf997e28586676565788b50e195fad	d__Bacteria; p__Bacteroidota; c__Bacteroidia; o__Bacteroidales; f__Bacteroidaceae; g__Bacteroides_H; s__Bacteroides_H caecimuris	0.9757376876270334
05452084756315 81b404f77c00d5b7f9	d__Bacteria; p__Bacteroidota; c__Bacteroidia; o__Bacteroidales; f__Marinifilaceae; g__Butyricimonas; s__Butyricimonas virosa	0.8024915724930316

Рис. 10. Фрагмент таблицы назначенной таксономии.

Confidence — уверенность наивного байесовского классификатора. По умолчанию таксон подписывается до самого глубокого уровня, где уверенность ≥ 0,7; поэтому некоторые строки обрываются на семействе (f__Muribaculaceae, f__Lachnospiraceae) — род определить надёжно не удалось. Названия Greengenes2 следуют системе GTDB: бывшие Firmicutes разбиты на Firmicutes_A (класс Clostridia: Lachnospiraceae, Oscillospiraceae), Firmicutes_D (Bacilli), Firmicutes_B и т. д.; числовые суффиксы вроде _258483 различают группы с

одинаковыми названиями.

Классификатор обучен на V4 (515F–806R) — ровно том участке, который секвенировали. В показанном фрагменте типичные обитатели кишечника мыши: Lachnospiraceae и Oscillospiraceae (Firmicutes_A), Muribaculaceae, Rikenellaceae, Bacteroidaceae (Bacteroidota); у 11 из 12 строк confidence выше 0,93. Названия видов (s__…) по 250 п.н. V4 ненадёжны — интерпретировать лучше на уровне рода и семейства.

1A.7. Состав сообществ: типы и классы

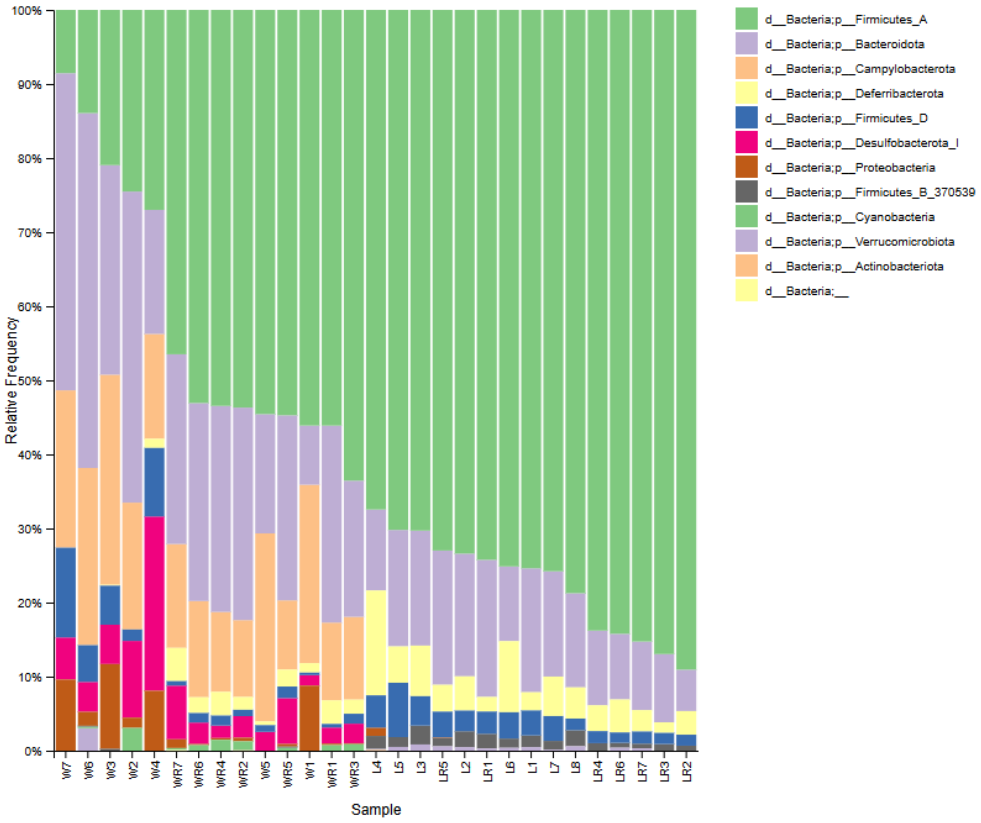


Рис. 11. Относительная представленность типов (Level 2). Образцы отсортированы по доле Firmicutes_A.

Каждый столбец — один образец, высота цветного блока — доля таксона (в сумме 100%). В view.qiime2.org: Taxonomic Level → Level 2 (тип) или Level 3 (класс); Sort Samples By → group, чтобы образцы шли по группам. Цвета в легенде повторяются (Firmicutes_A и Cyanobacteria оба зелёные): порядок слоёв в столбце совпадает с порядком легенды, а точное название видно при наведении курсора.

Группа	Firmicutes_A	Bacteroidota	Campylobacterota	Что ещё заметно
L, LR	≈ 65–90%	≈ 5–16%	≈ 0	Deferribacterota до ≈ 14% (L4, L6); немного Firmicutes_D (Bacilli) и Firmicutes_B
WR	≈ 46–64%	≈ 18–29%	≈ 9–14%	Desulfobacterota_I ≈ 2–8%; профили похожи между животными
W	≈ 8–56%	≈ 8–48%	≈ 14–29%	Desulfobacterota_I до ≈ 24% (W4), Proteobacteria до ≈ 12%, Firmicutes_D до ≈ 12%; животные сильно различаются

Значения считаны с рис. 11 и приблизительны.

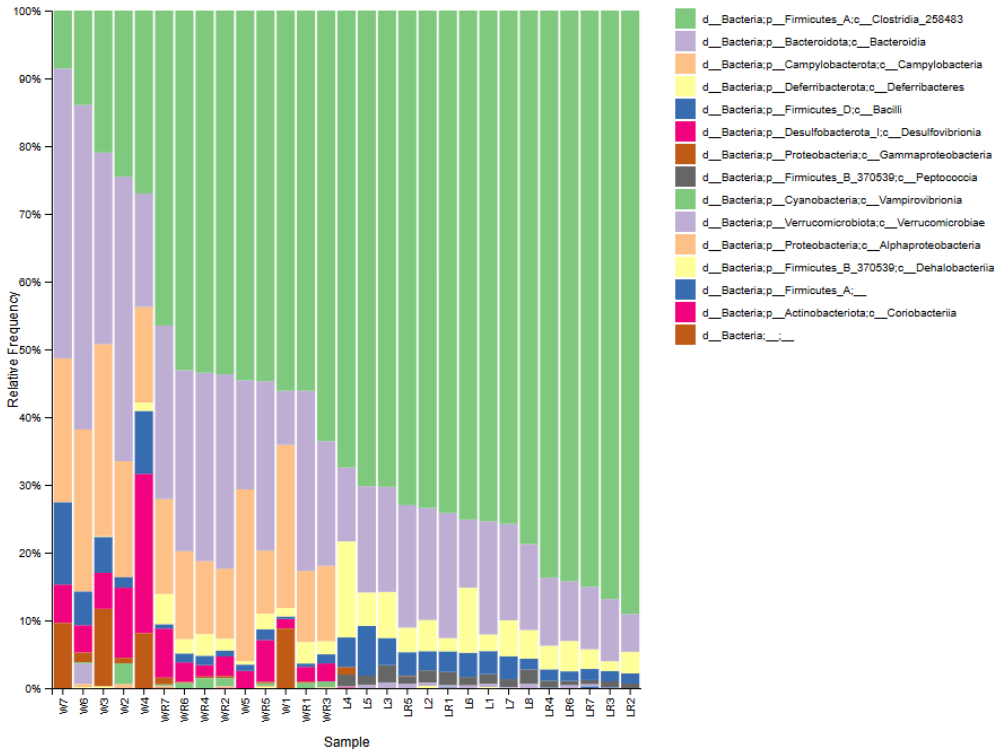


Рис. 12. Относительная представленность классов (Level 3).

На уровне классов картина та же: у L/LR доминирует Clostridia_258483 (Firmicutes_A), а у W/WR заметно больше Bacteroidia, Campylobacteria, Desulfovibrionia и (у W) Gammaproteobacteria.

Состав определяется происхождением микробиоты: L похожи на LR, W — на WR. У WR сохранились «дикие» группы (Campylobacterota, Desulfobacterota_I, больше Bacteroidota), которых почти нет у лабораторных мышей, — значит, пересаженная микробиота прижилась. W — самая неоднородная группа (разные животные из природы); WR однороднее, потому что живут в одинаковых условиях вивария.

В первой версии было сказано: «лабораторные L/LR характеризуются высоким вкладом Firmicutes_A и Bacteroidota» и «лабораторные образцы обогащены … Bacteroidia». По графикам наоборот: Bacteroidota/Bacteroidia у диких групп в 2–4 раза больше. Bacilli не отличают диких от лабораторных (есть и в L4–L5, и в W4, W7). Добавлены Deferribacterota — заметная группа именно у лабораторных мышей.

1A.8. Филогенетическое дерево ASV

Дерево строится из репрезентативных последовательностей ASV: MAFFT выравнивает их, маскирование убирает ненадёжные колонки выравнивания, FastTree строит дерево, затем оно укореняется по середине самой длинной ветви (midpoint rooting). Получается четыре файла: выравнивание, маскированное выравнивание, неукоренённое и укоренённое дерево.

Три вещи в дальнейшем анализе без дерева не считаются:

• UniFrac (и взвешенный, и невзвешенный) — расстояние между образцами, которое учитывает не только какие ASV есть, но и насколько они родственны. Замена одной бактерии на близкую родственницу даёт меньшее расстояние, чем на представителя другого типа.

• Faith PD — альфа-метрика: суммарная длина ветвей дерева, ведущих к ASV данного образца. Она показывает, насколько эволюционно разнообразно сообщество, а не только сколько в нём вариантов.

• Проверка артефактов: аномально длинная одиночная ветвь обычно означает, что в таблицу попала нецелевая последовательность (хлоропласт, остаток химеры, ошибка), и такой ASV стоит проверить BLAST.

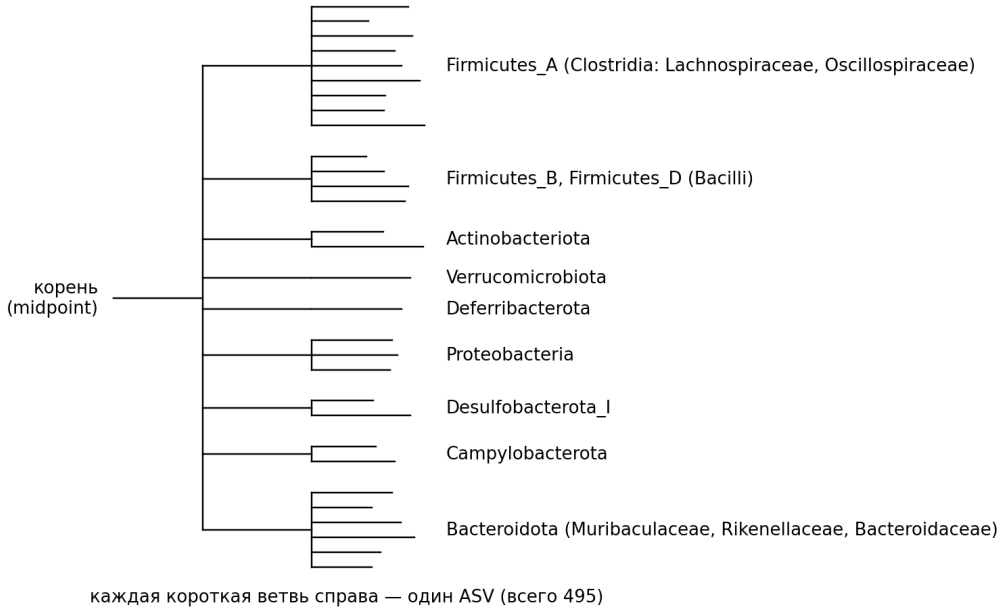


Рис. 13. Схема того, что должно получиться: 495 ASV группируются в клады, соответствующие типам бактерий. Это схема структуры, а не реальное дерево из данных.

На вашем дереве ASV одного типа (Firmicutes_A, Bacteroidota, Campylobacterota и т. д.) собираются в отдельные клады; больше всего листьев — у Firmicutes_A и Bacteroidota, поскольку именно они доминируют по численности; «дикие» группы (Campylobacterota, Desulfobacterota_I) образуют отдельные небольшие ветви — они и дают большой вклад в UniFrac-расстояние между лабораторными и дикими мышами.

Раскраска ветвей по таксономии (Level 2) — самый наглядный способ показать это: если клады окрашены в основном однородно, значит классификация и дерево согласуются между собой.

Скриншот 2. Дерево ASV mice. Как получить: qiime empress tree-plot (если плагин не установлен — например, через qiime2 empress или любой просмотрщик, открывающий mice_rooted_tree.qza), затем открыть mice_tree.qzv на view.qiime2.org и выбрать раскраску по mice_taxonomy.qza, Level 2. В прежней версии страница Empress не загрузилась — в этом случае достаточно указать, что дерево построено и использовано в расчёте UniFrac и Faith PD.

1A.9. Альфа-разнообразие

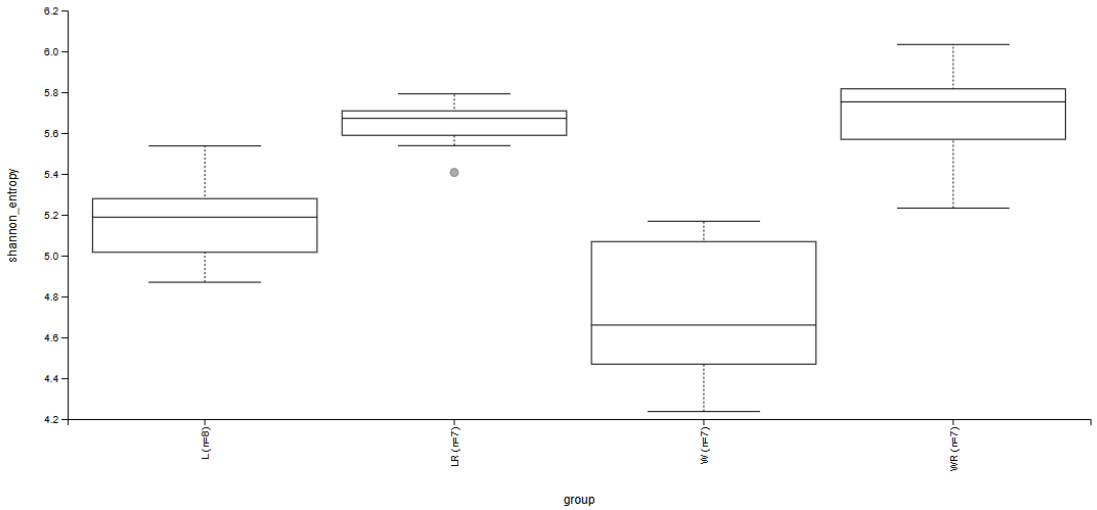


Рис. 14. Индекс Шеннона по группам (глубина разрежения 1 490).

Индекс Шеннона H = −Σ p·log2 p, где p — доля ASV. Он растёт и с числом ASV, и с равномерностью их долей. QIIME 2 считает его по основанию 2, поэтому удобно перевести в «эффективное число ASV» = 2 в степени H — столько одинаково обильных ASV дали бы такой же H. На boxplot линия — медиана, ящик — средние 50% образцов, усы — разброс, отдельные точки — выбросы.

Группа	Медиана H (≈)	Эффективное число ASV (≈)
L	5,2	37
LR	5,7	52
W	4,65	25
WR	5,75	54

		H	p-value	q-value
Group 1	Group 2			
L (n=8)	LR (n=7)	9.763393	0.001780	0.003560
	W (n=7)	4.834821	0.027891	0.033469
	WR (n=7)	7.714286	0.005479	0.008218
LR (n=7)	W (n=7)	9.800000	0.001745	0.003560
	WR (n=7)	1.179592	0.277439	0.277439
W (n=7)	WR (n=7)	9.800000	0.001745	0.003560

Рис. 15. Попарный тест Краскела–Уоллиса для индекса Шеннона.

Тест Краскела–Уоллиса сравнивает группы по рангам, не предполагая нормального распределения. q-value — это p-value с поправкой на множественные сравнения (Benjamini–Hochberg): при шести парах без поправки легко получить ложную значимость. Различие считаем значимым при q < 0,05.

Значимы пять пар из шести; не различаются только LR и WR (q = 0,277). Обе группы пересаженных мышей, живущих в одинаковых условиях, имеют самое высокое и близкое разнообразие; L ниже, W — ниже всех и с наибольшим разбросом.

То, что у диких мышей разнообразие самое низкое, стоит обсудить, а не замалчивать: микробиом диких мышей обычно описывают как более разнообразный. Возможные причины расхождения: у отдельных диких животных сообщество доминировано немногими группами (Bacteroidota и Campylobacterota), что снижает равномерность; разрежение всего до 1 490 ридов; маленькие группы (n = 7–8).

Другие альфа-метрики, которые уже посчитаны

Команда core-metrics-phylogenetic кроме Шеннона выдала ещё три вектора, и их стоит показать: observed_features (сколько ASV наблюдается — только богатство), evenness (равномерность Пиелу J = H / ln S) и faith_pd (филогенетическое разнообразие). Они отвечают на разные вопросы и помогают понять, чем именно отличаются группы.

Если низкий Шеннон у W объясняется доминированием немногих групп, то у W должна быть самая низкая равномерность Пиелу, а вот Faith PD у диких мышей может оказаться не ниже, а даже выше, чем у лабораторных: у них есть целые типы (Campylobacterota, Desulfobacterota_I), которых у лабораторных нет, и эти ветви дерева добавляют длину. Такое расхождение между метриками — хороший материал для обсуждения в отчёте.

Скриншот 4. Boxplot и таблица значимости для evenness_vector.qza и faith_pd_vector.qza (команда qiime diversity alpha-group-significance, группировка по group). Команда: qiime diversity alpha-group-significance по evenness_vector.qza и faith_pd_vector.qza.

1A.10. Бета-разнообразие

		Sample size	Permutations	pseudo-F	p-value	q-value
Group 1	Group 2					
L	LR	15	999	6.022143	0.001	0.001
	W	15	999	25.732437	0.001	0.001
	WR	15	999	40.359601	0.001	0.001
LR	W	14	999	24.206208	0.001	0.001
	WR	14	999	35.323119	0.001	0.001
W	WR	14	999	9.328730	0.001	0.001

Рис. 16. Попарный PERMANOVA по weighted UniFrac, 999 перестановок.

PERMANOVA сравнивает расстояния между группами с разбросом внутри групп. pseudo-F — во сколько раз межгрупповые различия превышают внутригрупповой разброс: чем больше, тем сильнее разделены группы. p-value получают перестановками меток групп; при 999 перестановках минимально возможное p = 1/(999 + 1) = 0,001. Все пары упёрлись в этот «пол», поэтому силу эффекта сравниваем по pseudo-F.

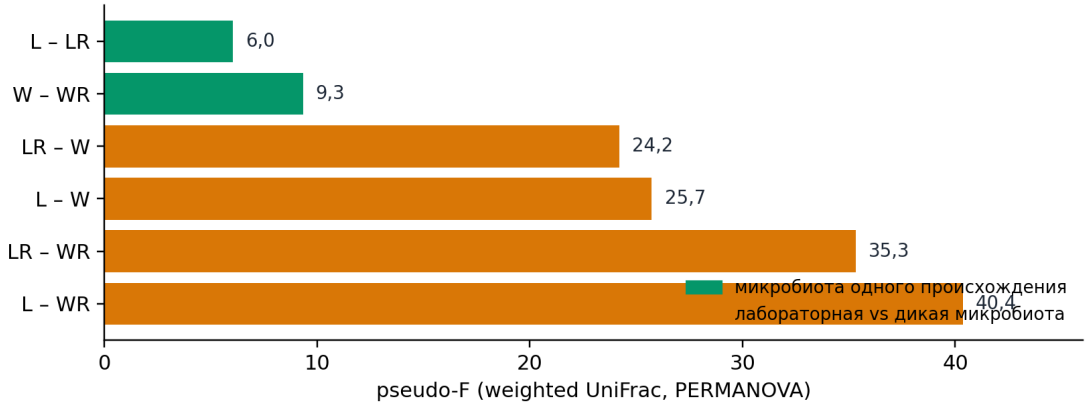


Рис. 17. pseudo-F для всех пар групп (по данным рис. 16).

Пары с микробиотой одного происхождения различаются слабо (L–LR 6,0; W–WR 9,3), а пары «лабораторная против дикой» — в 3–7 раз сильнее (24,2–40,4). Все шесть пар значимы (q = 0,001).

Главный фактор, определяющий структуру сообщества, — происхождение микробиоты (лабораторная или дикая); пересадка это различие сохранила. Второй, более слабый фактор — «родные» против «пересаженных» (условия содержания, генотип хозяина, поколения после пересадки). Оговорка: PERMANOVA чувствительна и к разнице в разбросе групп, а W очень неоднородны; проверить это можно тем же beta-group-significance с --p-method permdisp.

pseudo-F для пары L–W равен 25,732 (в первой версии была опечатка 25,723). Добавлена интерпретация величины pseudo-F: прежний вывод «каждая группа отличается от каждой» верен, но не показывал, какое различие главное.

Какие ещё матрицы расстояний уже посчитаны

core-metrics-phylogenetic строит четыре матрицы и четыре PCoA: weighted UniFrac (учитывает доли и родство), unweighted UniFrac (только присутствие/отсутствие и родство), Bray–Curtis (доли, без родства) и Jaccard (присутствие/отсутствие, без родства). Взвешенные метрики чувствительны к доминирующим таксонам, невзвешенные — к редким.

На PCoA по weighted UniFrac ожидаются два облака вдоль Axis 1: L + LR и W + WR, причём точки W разбросаны сильнее всех. На unweighted UniFrac разделение обычно ещё чётче, потому что у диких мышей есть целые линии бактерий, отсутствующие у лабораторных. Если картины сильно расходятся, это само по себе результат: значит, группы различаются не долями доминантов, а набором редких таксонов.

Скриншот 3. PCoA (Emperor) по weighted и unweighted UniFrac для mice, раскраска по group. Файлы: core_metrics_mice/weighted_unifrac_emperor.qzv и unweighted_unifrac_emperor.qzv. Подпишите проценты, которые объясняют оси.

1А.11. Итог по данным mice

Качество ридов хорошее; после DADA2 осталось ≈ 70% пар, 495 ASV в 29 образцах. Лабораторные и дикие мыши различаются составом кишечной микробиоты: у лабораторных доминируют Firmicutes_A (Clostridia), у диких больше Bacteroidota, Campylobacterota и Desulfobacterota_I. Пересаженная микробиота сохраняет своё происхождение: WR по составу и по UniFrac ближе к W, LR — к L; различия по происхождению в 3–7 раз сильнее, чем между родными и пересаженными группами. Альфа-разнообразие по Шеннону выше всего у пересаженных групп LR и WR, которые между собой не различаются.

Задача 1Б. FastQC почвенного образца SRR17307258_1

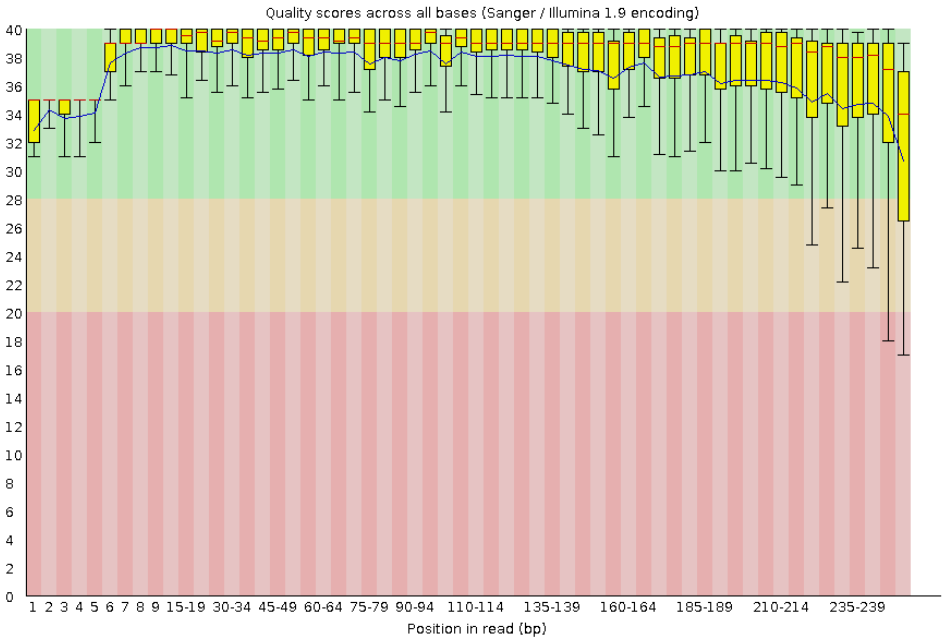


Рис. 18. Качество по позициям прямого рида SRR17307258_1.

Жёлтый ящик — средние 50% ридов в этой позиции, красная черта — медиана, синяя линия — среднее, усы — 10-й и 90-й процентили.

Позиции 1–5 чуть ниже (≈ 33–34) — это нормально для первых циклов прибора. С 6-й позиции примерно до 200 медиана 38–39; после ≈ 200 п.н. нижний квартиль опускается до 25–30, а в последней позиции ус доходит до ≈ 17. Усечение до 200 п.н. в DADA2 отрезает именно этот худший хвост.

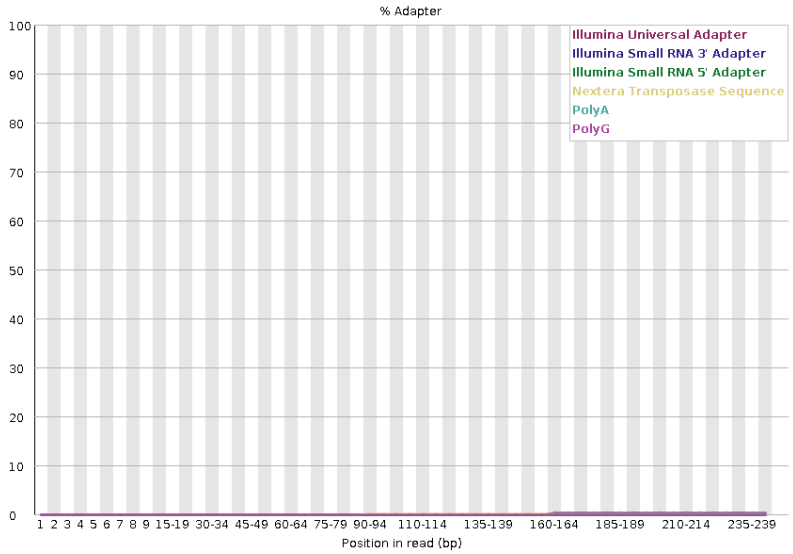


Рис. 19. Содержание адаптеров.

Адаптеров практически нет (≈ 0% по всей длине).

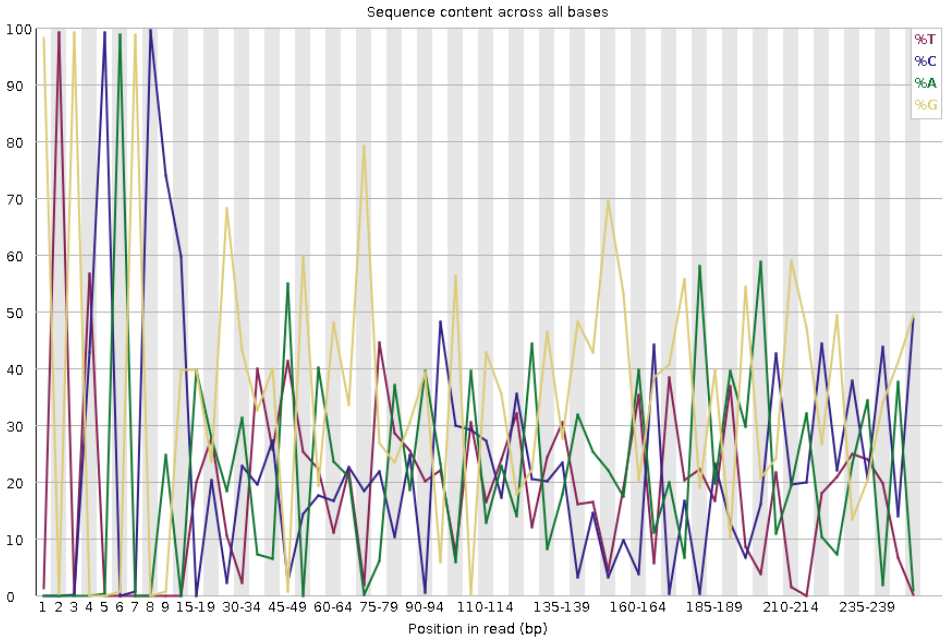


Рис. 20. Нуклеотидный состав по позициям.

Для каждой позиции показано, какая доля ридов несёт A, C, G или T. В случайной геномной библиотеке линии шли бы около 25%. В ампликоне все риды — копии одного гена, поэтому состав неравномерный, а там, где рид начинается с праймера, одна буква занимает почти 100%.

Позиция	1	2	3	4	5	6	7	8	9	10–14	15–19
515F по методичке	G	T	G	C	C	A	G	C	M	GCCGC	GGTAA
На графике	G	T	G	T 57% / C 43%	C	A	G	C	C 74% / A 25%	C 60%, G 40%	G 40, A 40, T 20%

Первые 19 позиций в точности повторяют праймер 515F: в позициях 10–14 доли C 60% и G 40% — это ровно три C и две G в GCCGC, в 15–19 — две G, две A и одна T в GGTAA. Позиция 9 содержит C и A — это вырожденная позиция M (A/C). В позиции 4 смесь T и C, то есть там стоит Y (C/T), хотя в методичке указан вариант с C: по-видимому, использована модифицированная версия праймера 515F-Y (GTGYCAGCMGCCGCGGTAA). После 19-й позиции состав остаётся неравномерным — это консервативный участок гена.

Качество высокое по всей длине, адаптеров нет. Риды начинаются с 19-нуклеотидного праймера 515F, который нужно отрезать (задача 2). Неравномерный нуклеотидный состав и FAIL в этом разделе FastQC — ожидаемое свойство ампликонной библиотеки.

В первой версии было написано про «неравномерность состава первых приблизительно 15–19 позиций». Праймер занимает ровно 19 позиций; добавлено наблюдение о вырожденных позициях 4 и 9 и о расхождении с последовательностью в методичке.

Задача 2. Зачем нужен --p-trim-left 25

Первые 19 нуклеотидов каждого R1 — это праймер 515F (рис. 20). Его последовательность задана синтетическим олигонуклеотидом, а не бактерией, поэтому она не несёт биологической информации и должна быть удалена.

Почему праймер мешает:

• Он искусственный. Праймер садится на матрицу и с небольшими несовпадениями, но в продукт ПЦР всегда попадает последовательность самого праймера — настоящие различия бактерий в этом месте стираются.

• Он вырожденный. В позициях 4 (C/T) и 9 (A/C) у разных молекул праймера разные буквы, поэтому одна и та же бактерия дала бы до четырёх вариантов начала рида. DADA2 принял бы их за разные ASV, и разнообразие искусственно завысилось бы.

• Он одинаков у всех: праймер садится на консервативный участок, различать по нему бактерии невозможно.

Лишние 6 нуклеотидов (позиции 20–25) отрезают с запасом: это тоже консервативный участок (рис. 20), а запас гарантирует, что все последовательности начинаются с одной и той же гомологичной позиции.

QIIME 2 сначала усекает рид справа (trunc-len 200), а потом отрезает слева (trim-left 25), поэтому каждый ASV имеет длину 200 − 25 = 175 п.н. Одинаковая длина обязательна: иначе одна и та же последовательность, прочитанная чуть длиннее, выглядела бы как другой ASV. Риды короче 200 п.н. DADA2 отбросил бы, но здесь все риды имеют длину 250 п.н.

Задача 3. Сколько прочтений осталось после DADA2

sample-id #q2:types	input numeric	filtered numeric	percentage of input passed filter numeric	denoised numeric	non-chimeric numeric	percentage of input non-chimeric numeric
SRR17307258	26992	26932	99.78	26472	25395	94.08
SRR17307262	5996	5926	98.83	5754	5731	95.58
SRR17307269	10387	10322	99.37	9859	9859	94.92
SRR17307273	23451	23405	99.8	23023	20966	89.4
SRR17307278	24834	24783	99.79	24230	23607	95.06
SRR17307316	10833	10723	98.98	10193	10189	94.06
SRR17307364	8661	8605	99.35	8270	8270	95.49
SRR17307380	5128	5087	99.2	4830	4809	93.78
SRR17307392	25424	25374	99.8	24617	24547	96.55
SRR17307400	9513	9351	98.3	9127	9077	95.42
SRR17307404	8614	8551	99.27	8158	8141	94.51
SRR17307406	22460	22420	99.82	21987	21190	94.35
SRR17307409	29485	29434	99.83	28819	28088	95.26
SRR17307413	9875	9740	98.63	9595	9532	96.53
SRR17307419	24624	24574	99.8	23982	23904	97.08
SRR17307420	9962	9873	99.11	9453	9441	94.77
SRR17307436	9471	9380	99.04	9019	8993	94.95

Рис. 21. Статистика DADA2 для почвенных образцов (видны первые 17 из 36 строк).

Данные одноконцевые (только R1), поэтому столбца merged нет: input → filtered → denoised → non-chimeric.

Показатель	Значение	Что это значит
Прошли фильтр качества	98,3–99,8%	риды качественные, maxEE 3 — мягкий порог
Дошли до конца (non-chimeric)	89,4–97,1%, типично ≈ 94–96%	потери небольшие и одинаковые по образцам
Самый большой образец	SRR17307475: 45 492 → 43 517 (95,66%)	наибольшая глубина
Самый маленький образец	SRR17307380: 5 128 → 4 809 (93,78%)	задаёт глубину разрежения
Разница глубин	43 517 / 4 809 ≈ 9	неравномерная загрузка библиотек при секвенировании

Больше всего химер среди видимых образцов у SRR17307273 (23 023 → 20 966, 89,4%) — обычный уровень. Для сравнения: у mice до конца дошло ≈ 70% пар, потому что там риды парные и много теряется на склейке; здесь склейки нет.

После всех стадий остаётся ≈ 95% исходных прочтений. Максимум — 43 517 (SRR17307475), минимум — 4 809 (SRR17307380). Высокая и равномерная доля сохранённых ридов говорит о хорошем качестве данных, согласуется с FastQC и показывает, что параметры DADA2 не слишком строгие. Девятикратная разница глубин связана с подготовкой библиотек, а не с качеством; её учитывают разрежением до 4 809 ридов.

Скриншот 5. Та же таблица, отсортированная по столбцу non-chimeric (клик по заголовку столбца в view.qiime2.org): нужны верхние и нижние строки, чтобы были видны самый большой и самый маленький образцы — сейчас их на скриншоте нет.

Скриншот 6. Сводка таблицы ASV по почве (qiime feature-table summarize): число образцов, число ASV, минимальная и максимальная глубина. Именно она обосновывает выбор --p-sampling-depth 4809 и показывает, сколько всего ASV найдено в почве — этого числа в отчёте пока нет.

Задача 4. Почему достаточно классификатора, обученного на V4

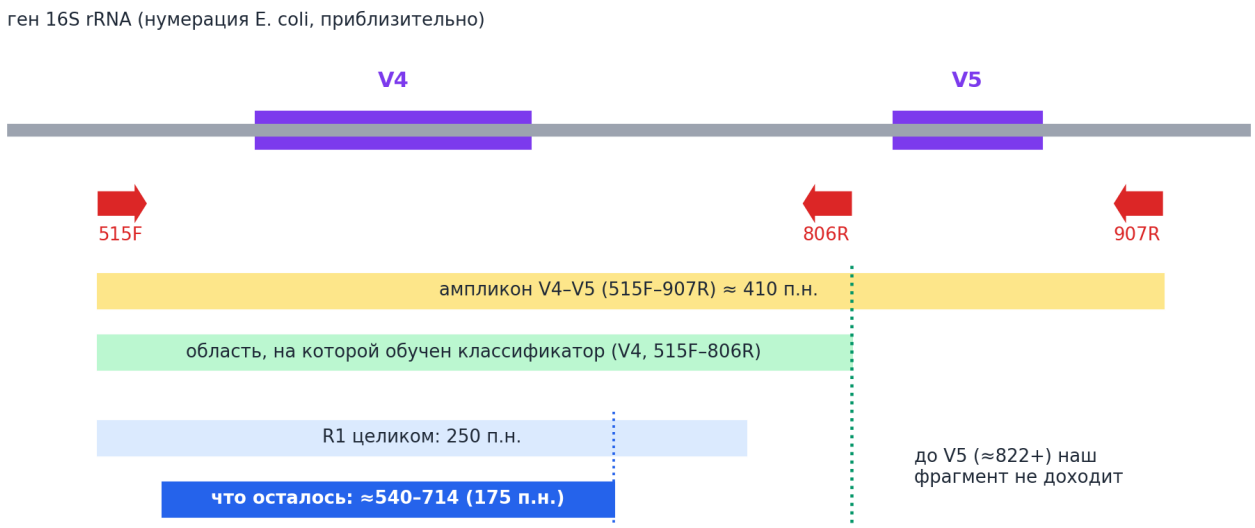


Рис. 22. Где на гене 16S лежит анализируемый фрагмент R1 (схема, координаты приблизительные).

Мы используем только прямые риды R1. Они начинаются на праймере 515F, а после усечения до 200 п.н. и обрезки 25 п.н. слева остаётся фрагмент ≈ 540–714 (175 п.н.). Он целиком лежит внутри области 515F–806R, на которой обучен классификатор. Регион V5 начинается после ≈ 820-й позиции, и наш фрагмент до него не доходит.

Наивный байесовский классификатор сравнивает короткие подстроки (k-меры) запроса с k-мерами обучающих последовательностей. Если обучить его на полном V4–V5, большая часть признаков модели будет из участка, которого в наших ридах нет. Классификатор, обученный на том же участке, что и запросы, работает точнее.

Для контраста: если бы мы взяли обратные риды R2, они начинались бы на 907R и шли назад ≈ 250 п.н., покрывая V5. Для них V4-классификатор уже не подошёл бы.

Хотя праймеры рассчитаны на V4–V5, после отказа от R2 и обрезки мы анализируем только участок внутри V4. Поэтому классификатор, обученный на V4, соответствует нашим данным лучше, чем классификатор для всего ампликона.

Задача 5. Таксономический состав почвенных сообществ

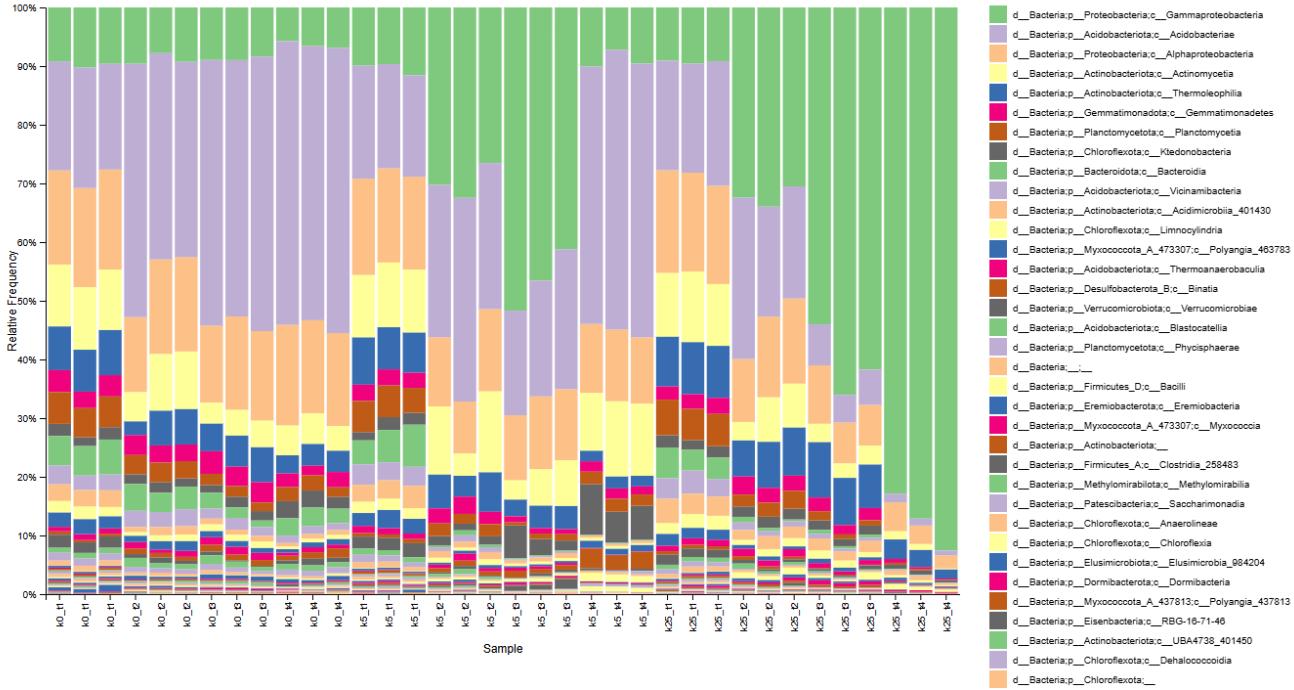


Рис. 23. Относительная представленность классов (Level 3), образцы упорядочены по level_and_time_point.

Порядок столбцов: k0_t1 … k0_t4, затем k5_t1 … k5_t4, затем k25_t1 … k25_t4 (по три повтора в каждой точке). Сверху вниз слои идут в порядке легенды: зелёный сверху — Gammaproteobacteria, фиолетовый — Acidobacteriae, оранжевый — Alphaproteobacteria, жёлтый — Actinomycetia, синий — Thermoleophilia.

В первой временной точке образцы похожи: все девять образцов t1 (k0, k5, k25) почти одинаковы, и повторы внутри группы очень близки: через 3 суток керосин ещё не успел перестроить сообщество.

Дальше три режима расходятся.

• k0 (контроль). Сообщество тоже меняется: доля Acidobacteriae растёт с ≈ 20% (t1) до ≈ 33–43% (t2) и ≈ 47–49% (t4), доли Actinomycetia и Thermoleophilia снижаются. Это эффект года инкубации в закрытой ёмкости, а не керосина.

• k5. Gammaproteobacteria растут до ≈ 27–32% (t2) и ≈ 41–52% (t3), а к t4 возвращаются к ≈ 7–10%; Acidobacteriae снова ≈ 44–48%. По классам профиль k5_t4 почти совпадает с k0_t4.

• k25. Gammaproteobacteria неуклонно растут: ≈ 30–34% (t2) → 54–66% (t3) → 83–93% (t4). Остальные классы почти исчезают.

Точка	Самые частые классы (≈ доля)
t1 (все уровни)	Acidobacteriae 17–21%, Alphaproteobacteria 16–17%, Actinomycetia ≈ 10%, Gammaproteobacteria 9–10%, Thermoleophilia 7–8%
t4, k0	Acidobacteriae 47–49%, Alphaproteobacteria 14–16%, Gammaproteobacteria 6–7%
t4, k5	Acidobacteriae 44–48%, Alphaproteobacteria ≈ 12%, Gammaproteobacteria 7–10%
t4, k25	Gammaproteobacteria 83–93%; все остальные классы — единицы процентов

Значения считаны с рис. 23 и приблизительны.

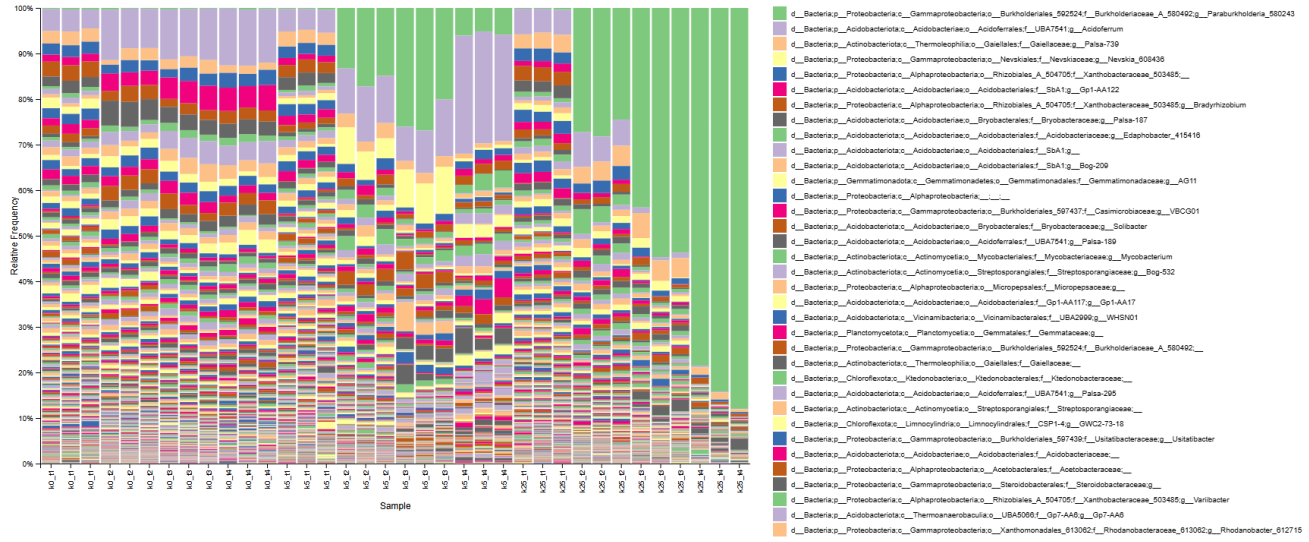


Рис. 24. Представленность родов (Level 6). Верхний зелёный слой — Paraburkholderia.

Самый частый род в загрязнённых образцах — Paraburkholderia (семейство Burkholderiaceae). Его доля: k5 — ≈ 13–17% (t2), ≈ 20–27% (t3), ≈ 5–6% (t4); k25 — ≈ 25–28% (t2), ≈ 44–55% (t3), ≈ 79–88% (t4). В контроле его практически нет.

В Greengenes2 (система GTDB) порядок Burkholderiales отнесён к классу Gammaproteobacteria, хотя в старой классификации (SILVA, NCBI) это Betaproteobacteria. Поэтому «рост Gammaproteobacteria» на рис. 23 и «рост Paraburkholderia» на рис. 24 — во многом одно и то же явление на разных уровнях.

Увидеть именно его при загрязнении керосином ожидаемо. Керосин — смесь алканов и ароматических углеводородов; представители Burkholderiaceae известны как деструкторы ароматических соединений, включая полициклические, и часто становятся доминирующим семейством в почвах, загрязнённых нефтепродуктами. Керосин одновременно убивает чувствительные группы и служит источником углерода для тех, кто умеет его разлагать.

Деталь, которую стоит отметить: к t4 профиль k5 по классам похож на контроль, но по родам отличается (например, доля Acidoferrum в k5_t4 ≈ 25% против ≈ 10–12% в k0_t4). Сообщество вернулось к похожей структуре, но не к исходному набору родов.

Рост относительной доли не равен росту численности: доля Paraburkholderia может расти и потому, что она размножается, и потому, что вымирают остальные. Относительные данные 16S этого не различают.

В начале эксперимента все образцы одинаковы. Со временем сильное загрязнение (k25) превращает сообщество почти в монокультуру Gammaproteobacteria (Paraburkholderia до ≈ 80–88%). Слабое загрязнение (k5) вызывает временный всплеск тех же групп, но к 360 суткам классовый профиль возвращается к контрольному. Контроль тоже меняется (рост Acidobacteriae) — это эффект условий инкубации.

В первой версии не было ответа на вопрос о самых частых классах в первой и последней точках; он добавлен таблицей выше. Уточнено также, что контроль тоже заметно меняется со временем.

Задача 6. Бета-разнообразие: PCoA по weighted UniFrac

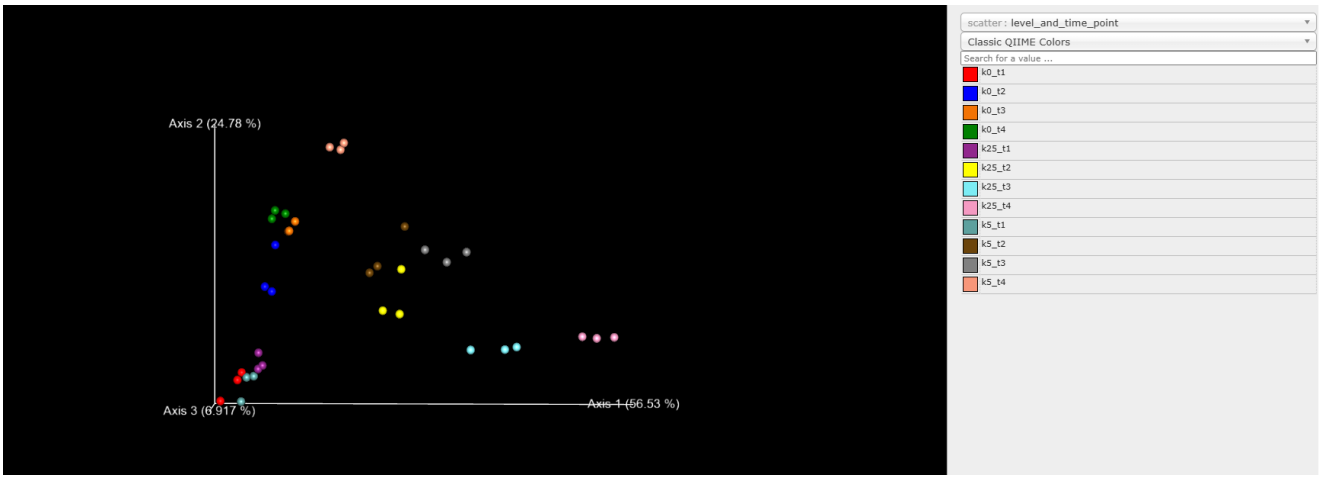


Рис. 25. PCoA по weighted UniFrac, цвет — level_and_time_point.

Каждая точка — образец; чем ближе точки, тем более похожи сообщества. Weighted UniFrac учитывает доли ASV и их родство по дереву (раздел 1А.8). Оси — главные координаты; в скобках — доля изменчивости, которую объясняет ось: Axis 1 — 56,5%, Axis 2 — 24,8%, Axis 3 — 6,9% (вместе ≈ 88%). В Emperor раскраска задаётся во вкладке Color выбором столбца level_and_time_point.

В первой временной точке образцы похожи: k0_t1, k5_t1 и k25_t1 лежат плотным облаком в левом нижнем углу, как и на barplot.

Дальше траектории групп расходятся.

• k0: смещается вверх по Axis 2 (t1 → t2 → t3 ≈ t4) и почти не сдвигается по Axis 1.

• k5: t2 и t3 уходят вправо по Axis 1; t4 возвращается влево, почти на уровень контроля по Axis 1, но располагается выше всех по Axis 2 — рядом с k0_t4, но не совпадает с ним.

• k25: последовательно уходит вправо по Axis 1 (t2 → t3 → t4) и к 360 суткам находится дальше всех от контроля.

Axis 1 — эффект керосина: вдоль неё выстраиваются загрязнённые образцы в порядке роста доли Gammaproteobacteria и Paraburkholderia. Axis 2 — время инкубации: по ней сдвигается даже контроль (рост Acidobacteriae). Оговорка: образцы горшечного эксперимента секвенировали в трёх запусках (3-и сутки; 90-е и 180-е; 360-е), так что часть сдвига по времени может быть технической; weighted UniFrac к этому менее чувствителен, чем Bray–Curtis.

Самые сильные изменения (Axis 1) вызваны керосином и нарастают с дозой и временем. Признаки восстановления есть у k5: к 360 суткам образцы вернулись к контролю по Axis 1, хотя и не совпали с ним полностью. У k25 восстановления за год нет — образцы продолжают удаляться от контроля.

В первой версии было сказано, что k0 остаётся в левой области и сдвиг небольшой. По Axis 1 это верно, но по Axis 2 (≈ 25% изменчивости) контроль смещается заметно; это согласуется с ростом Acidobacteriae на barplot и было противоречием внутри отчёта.

Картинка показывает различия, но не проверяет их статистически. PERMANOVA по столбцу contamination_level (и отдельно по level_and_time_point) даст pseudo-F и p-value и позволит сказать, значимы ли различия. Ожидается: k0 против k25 — большой pseudo-F и p = 0,001; k0 против k5 — значимо, но слабее. Учтите, что при группировке только по уровню загрязнения в одну группу попадают все четыре времени, включая t1, где различий ещё

нет, — это занижает эффект.

Скриншот 7. Результат qiime diversity beta-group-significance (weighted UniFrac, --m-metadata-column contamination_level, --p-method permanova, --p-pairwise): таблица с pseudo-F и q-value.

Задача 7. Альфа-разнообразие: индекс Шеннона во времени

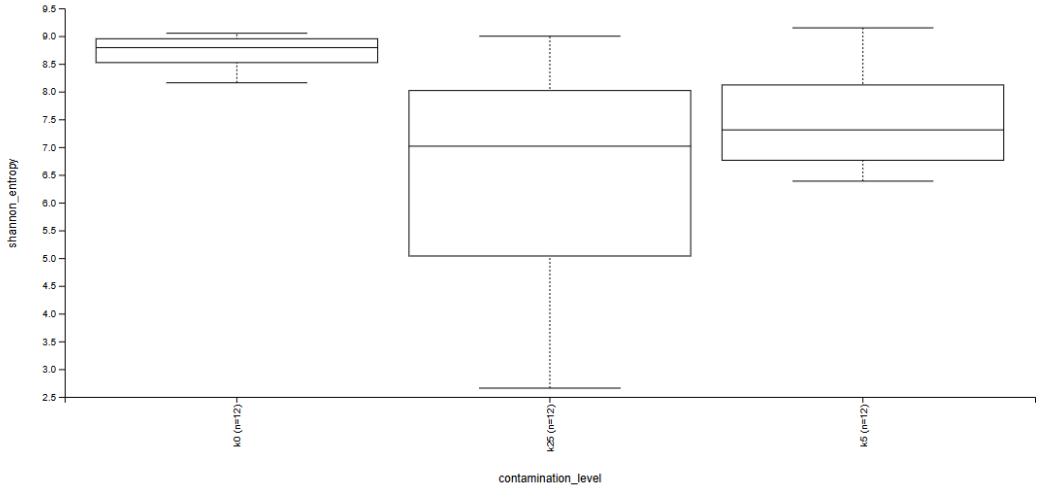


Рис. 26. Индекс Шеннона по уровню загрязнения (все времена вместе, n = 12).

Здесь в одну группу смешаны все четыре времени, поэтому ящики k5 и k25 очень широкие: в них попадают и t1 (ещё не затронутые), и t4. Динамику правильнее смотреть на рис. 27, где группы разбиты по времени (в view.qiime2.org — выбор столбца level_and_time_point в списке Category).

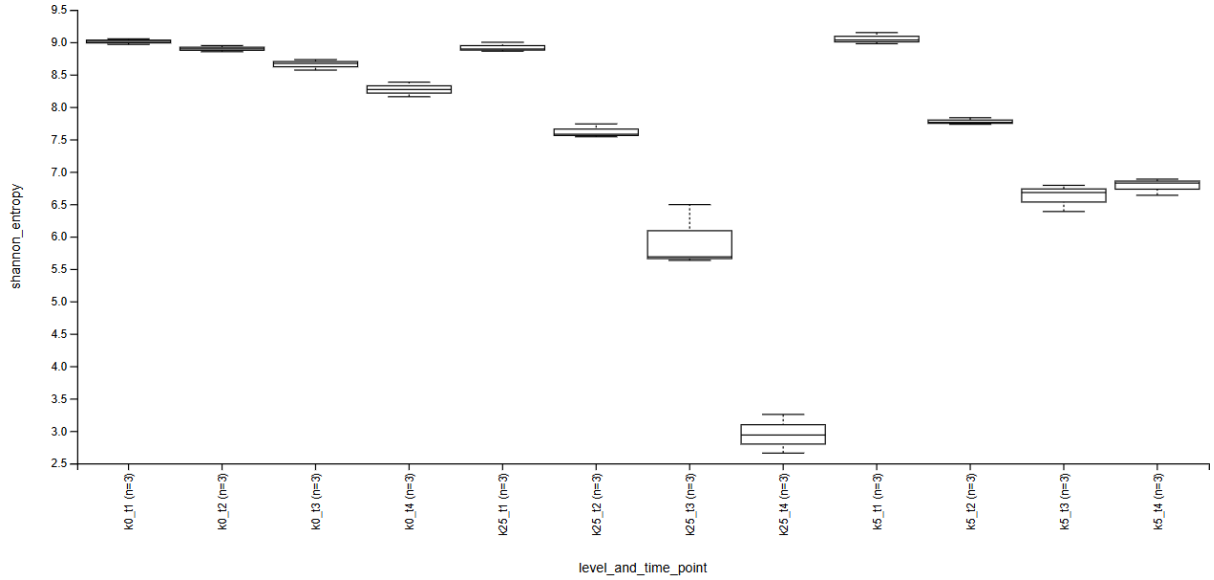


Рис. 27. Индекс Шеннона по сочетаниям уровня загрязнения и времени (n = 3).

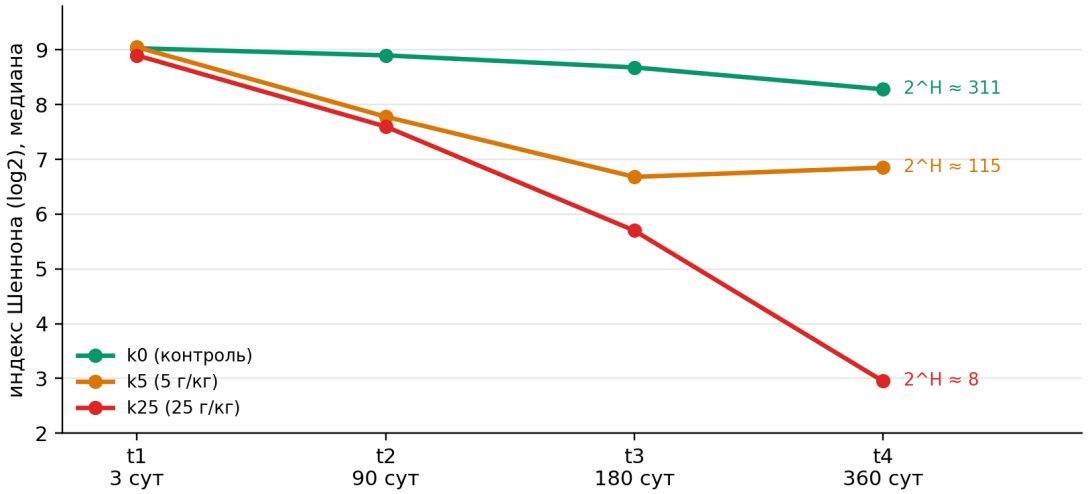


Рис. 28. Медианы индекса Шеннона из рис. 27 (считаны с графика) и эффективное число ASV в последней точке.

Условие	t1 (3 сут)	t2 (90 сут)	t3 (180 сут)	t4 (360 сут)	Эффективное число ASV в t4
k0	9,03	8,90	8,68	8,28	≈ 310 (в t1 ≈ 520)
k5	9,05	7,78	6,68	6,85	≈ 115
k25	8,90	7,60	5,70	2,95	≈ 8

• k0: медленный спад. В единицах H всего ≈ 0,75, но в «эффективных ASV» это почти вдвое меньше (≈ 520 → ≈ 310). Вероятная причина — год в закрытой ёмкости: истощение питательных веществ и отсутствие притока новых бактерий.

• k5: резкое падение до 180 суток, затем падение прекращается (6,68 → 6,85 — в пределах разброса трёх повторов). Это скорее стабилизация, чем восстановление: в t4 разнообразие всё ещё ≈ 1,4 единицы ниже контроля, то есть «эффективных» ASV примерно в 2,7 раза меньше.

• k25: непрерывный обвал до ≈ 3, то есть около 8 «эффективных» ASV из сотен. Сообщество доминировано одним родом (Paraburkholderia ≈ 80–88%).

Керосин снижает разнообразие дозозависимо. При сильном загрязнении падение продолжается весь год. При слабом оно останавливается к 180–360 суткам, но до уровня контроля не возвращается. Вместе с задачами 5–6 это означает, что восстановление k5 частичное: структура сообщества (классы, положение по Axis 1) почти вернулась, а разнообразие — нет.

В первой версии у k5 отмечен «слабый подъём к 360 суткам … разворот к восстановлению». Подъём 6,68 → 6,85 лежит в пределах разброса повторов, а разнообразие остаётся намного ниже контроля. Добавлен перевод H в «эффективное число ASV», чтобы масштаб изменений был нагляден.

В том же файле soil_shannon_significance.qzv под графиком есть таблица Краскела–Уоллиса — из неё видно, значимы ли различия. Ожидается: k0 против k25 значимо, k0 против k5 тоже; при разбивке по 12 группам «уровень × время» в каждой всего по 3 образца, поэтому попарные тесты почти не имеют мощности — на это стоит сослаться в тексте.

Скриншот 8. Нижняя часть страницы soil_shannon_significance.qzv: таблица Kruskal–Wallis (all groups) и попарная таблица с q-value.

Дополнительно по почве стоит показать Faith PD и равномерность Пиелу: при доминировании одного рода равномерность в k25_t4 должна упасть почти до нуля, а Faith PD — резко снизиться, потому что из сообщества исчезают целые линии (alpha-group-significance по evenness_vector.qza и faith_pd_vector.qza).

Итоговые выводы

Данные mice

Качество ридов хорошее, после DADA2 сохранилось ≈ 70% пар и 495 ASV в 29 образцах. Состав кишечной микробиоты определяется её происхождением: у лабораторных мышей доминируют Firmicutes_A (Clostridia), у диких больше Bacteroidota, Campylobacterota и Desulfobacterota_I. Пересаженная микробиота сохраняет своё происхождение: по UniFrac различия «лабораторная против дикой» в 3–7 раз сильнее, чем «родные против пересаженных». Альфа-разнообразие по Шеннону выше всего у пересаженных групп LR и WR, которые между собой не различаются.

Данные soil

Качество ридов высокое; после DADA2 остаётся ≈ 95% прочтений, глубина от 4 809 до 43 517. В начале эксперимента все образцы одинаковы. Керосин действует как экологический фильтр: сильное загрязнение (k25) за год превращает сообщество почти в монокультуру Paraburkholderia (Gammaproteobacteria до ≈ 90%), индекс Шеннона падает с ≈ 9 до ≈ 3, образцы уходят вдоль Axis 1 всё дальше от контроля — восстановления нет. Слабое загрязнение (k5) вызывает временный всплеск тех же групп; к 360 суткам классовый состав и положение по Axis 1 возвращаются к контролю, но разнообразие остаётся заметно ниже — восстановление частичное. Контроль тоже меняется со временем (рост Acidobacteriae, небольшое снижение разнообразия) — это эффект инкубации в закрытой ёмкости, который нужно отделять от эффекта керосина.